ГУАП

КАФЕДРА №

41

ОТЧЕТ
ЗАЩИЩЕН С ОЦЕНКОЙ

ПРЕПОДАВАТЕЛЬ

старший преподаватель		В. В. Боженко
должность, уч. степень, звание	подпись, дата	инициалы, фамилия

ОТЧЕТ О ЛАБОРАТОРНОЙ РАБОТЕ №1

Предварительный анализ данных

по курсу: Введение в анализ данных

РАБОТУ ВЫПОЛНИЛ

СТУДЕНТ гр. №	4417		М. П. Курбатов
		подпись, дата	инициалы, фамилия

Санкт-Петербург 2026

Цель работы: осуществить предварительную обработку данных csv-файла, выявить и устранить проблемы в этих данных.

Вариант для выполнения работы — №13 (набор данных movies.csv). Набор данных относится к предметной области кинематографа и содержит сведения о фильмах: название (title), год выхода (release_year), рейтинг (score), количество голосов (number_of_votes), продолжительность (duration), основной жанр (main_genre) и основную страну производства (main_production).

ПОРЯДОК ВЫПОЛНЕНИЯ РАБОТЫ

1. Чтение файла

Для выполнения работы файл movies.csv загружен в Google Colab. Импорт библиотек и чтение набора данных выполняются один раз. Фрагмент кода приведён на рисунке 1, первые строки загруженной таблицы — на рисунке 2.

```
import pandas as pd
from IPython.display import display

file_path = '/var/movies.csv'
tabl = pd.read_csv(file_path, sep=';')
print('Размер исходного набора:', tabl.shape)
display(tabl.head())
```

Рисунок 1 — Реализация чтения

	title	release_year	score	number_of_votes	duration	main_genre	main_production
0	David Attenborough: A Life on Our Planet	2020.0	9.0	31180.0	83	documentary	GB
1	Inception	2010.0	8.8	2268288.0	148	scifi	GB
2	Forrest Gump	1994.0	8.8	1994599.0	142	drama	US
3	Anbe Sivam	2003.0	8.7	20595.0	160	comedy	IN
4	Bo Burnham: Inside	2021.0	8.7	44074.0	87	comedy	US

Рисунок 2 — Фрагмент загруженной таблицы

2. Обзор данных.

2.1. Вывод первых 20 строк с помощью метода head.

Вывод первых нескольких строк осуществляется с помощью метода head(), в скобках которого указывается количество выводимых строк. В данном случае первые 20. Реализация и результат выполнения представлен на рисунках 3-4.

```
display(tabl.head(20))
```

Рисунок 3 — Реализация метода head()

	title	release_year	score	number_of_votes	duration	main_genre	main_production
0	David Attenborough: A Life on Our Planet	2020.0	9.0	31180.0	83	documentary	GB
1	Inception	2010.0	8.8	2268288.0	148	scifi	GB
2	Forrest Gump	1994.0	8.8	1994599.0	142	drama	US
3	Anbe Sivam	2003.0	8.7	20595.0	160	comedy	IN
4	Bo Burnham: Inside	2021.0	8.7	44074.0	87	comedy	US
5	Saving Private Ryan	1998.0	8.6	1346020.0	169	drama	US
6	Django Unchained	2012.0	8.4	1472668.0	165	western	US
7	Dangal	2016.0	8.4	180247.0	161	action	IN
8	Bo Burnham: Make Happy	2016.0	8.4	14356.0	60	comedy	US
9	Louis C.K.: Hilarious	2010.0	8.4	11973.0	84	comedy	US
10	Dave Chappelle: Sticks & Stones	2019.0	8.4	25687.0	65	comedy	US
11	3 Idiots	2009.0	8.4	385782.0	170	comedy	IN
12	Black Friday	2004.0	8.4	20611.0	143	crime	IN
13	Super Deluxe	2019.0	8.4	13680.0	176	thriller	IN
14	Winter on Fire: Ukraine's Fight for Freedom	2015.0	8.3	17710.0	98	documentary	UA
15	Once Upon a Time in America	1984.0	8.3	342335.0	229	drama	US
16	Taxi Driver	1976.0	8.3	795222.0	113	crime	US
17	Like Stars on Earth	2007.0	8.3	188234.0	165	drama	IN
18	Bo Burnham: What.	2013.0	8.3	11488.0	60	comedy	US
19	Full Metal Jacket	1987.0	8.3	723306.0	116	drama	GB

Рисунок 4 — Вывод первых 20 строк

2.2. Оценка данных с помощью метода info().

С помощью метода info() можно узнать типы данных по каждому столбцу и подсчёт непустых ячеек по каждому столбцу. Реализация и результат выполнения представлены на рисунках 5-6.

```
tabl.info()
```

Рисунок 5 — Реализация метода info()

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 389 entries, 0 to 388
Data columns (total 7 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   title            384 non-null    object
 1   release_year     387 non-null    float64
 2   score            386 non-null    float64
 3   number_of_votes  388 non-null    float64
 4   duration         389 non-null    int64
 5   main_genre       389 non-null    object
 6   main_production  388 non-null    object
dtypes: float64(3), int64(1), object(3)
memory usage: 21.4+ KB
```

Рисунок 6 — Вывод информации по таблице

2.3. Оценка данных с помощью метода describe().

Метод describe() используется для получения основных статистических характеристик числовых столбцов набора данных. Он позволяет определить количество непустых значений, среднее значение, стандартное отклонение, минимальное и максимальное значения, а также квартили. Реализация и результат представлены на рисунках 7–8.

```
display(tabl.describe())
```

Рисунок 7 — Написание программы для вывода статистических величин

	release_year	score	number_of_votes	duration
count	387.000000	386.000000	3.880000e+02	389.000000
mean	2010.976744	7.512176	1.391523e+05	123.352185
std	10.805726	0.443870	2.365279e+05	28.304800
min	1954.000000	6.900000	1.013900e+04	28.000000
25%	2007.500000	7.100000	2.055375e+04	104.000000
50%	2014.000000	7.400000	4.606950e+04	122.000000
75%	2018.000000	7.800000	1.551585e+05	139.000000
max	2022.000000	9.000000	2.268288e+06	229.000000

Рисунок 8 — Таблица с описательной статистикой

В исходном наборе данных содержится 389 строк. Метод describe() показал, что фильмы выпущены в период с 1954 по 2022 год. Средний рейтинг составляет около 7,5, минимальный — 6,9, максимальный — 9,0. Средняя продолжительность фильма составляет около 123 минут, минимальная — 28 минут, максимальная — 229 минут. Значения count меньше 389 для некоторых столбцов указывают на наличие пропущенных значений.

2.4. Оценка названий столбцов.

Названия столбцов были проверены с помощью атрибута tabl.columns, который возвращает объект Index с названиями столбцов. Названия оформлены в едином стиле, не содержат пробелов и соответствуют содержимому столбцов, поэтому переименование не требуется. Реализация и результат представлены на рисунках 9–10.

```
print(tabl.columns.tolist())

assert tabl.columns.is_unique
```

Рисунок 9 — Реализация программы

```
['title', 'release_year', 'score', 'number_of_votes', 'duration', 'main_genre', 'main_production']
```

Рисунок 10 — Результат выполнения

3. Проверка пропусков.

Проверка пропусков осуществляется с помощью метода .isna().sum(), который подсчитывает количество пропусков в таблице. Реализация и выполнение представлены на рисунках 11-12.

```
display(tabl.isna().sum().to_frame('Пропусков'))
print('Строк с пропусками:', tabl.isna().any(axis=1).sum())
```

Рисунок 11 — Реализация подсчёта пропусков в датасете

	Пропусков
title	5
release_year	2
score	3
number_of_votes	1
duration	0
main_genre	0
main_production	1

```
Строк с пропусками: 6
```

Рисунок 12 — Вывод результата

Как видно из результата выполнения программы, в исходном наборе данных присутствуют пропущенные значения в нескольких столбцах: 5 пропусков в title, 2 — в release_year, 3 — в score, 1 — в number_of_votes и 1 — в main_production. В столбцах duration и main_genre пропуски отсутствуют. Всего обнаружено 6 строк, содержащих хотя бы одно пропущенное значение.

Так как количество таких строк невелико по сравнению с общим объёмом набора данных, было принято решение удалить их. Замена пропусков средними или медианными значениями в данном случае могла бы привести к искажению информации о фильмах, особенно для таких признаков, как название, год выпуска, рейтинг и страна производства.

Удаление строк с пропущенными значениями выполняется с помощью конструкции tabl = tabl.dropna().copy(). Метод dropna() удаляет строки, содержащие хотя бы одно пустое значение, а метод copy() создаёт независимую копию полученного набора данных. После выполнения операции была проведена повторная проверка с помощью tabl.isna().sum(), которая показала отсутствие пропущенных значений. После обработки в наборе данных осталось 383 строки. Реализация и результат выполнения программы представлены на рисунках 13–14.

```
tabl = tabl.dropna().copy()
print('Пропуски после удаления строк:')
print(tabl.isna().sum())
print('Размер после удаления пропусков:', tabl.shape)
```

Рисунок 13 — Реализация удаления пропусков

```
Пропуски после удаления строк:
title              0
release_year       0
score              0
number_of_votes    0
duration           0
main_genre         0
main_production    0
dtype: int64
Размер после удаления пропусков: (383, 7)
```

Рисунок 14 — Проверка верного выполнения программы

4. Проверка дубликатов.

Проверка явных дубликатов осуществляется с помощью метода duplicated().sum(), который подсчитывает количество полностью повторяющихся строк. В исходном наборе было обнаружено 2 явных дубликата. Они были удалены методом drop_duplicates(), после чего повторная проверка показала 0 дубликатов. Реализация и результат представлены на рисунках 15–16.

```
print('Явных дубликатов до удаления:', tabl.duplicated().sum())

tabl = tabl.drop_duplicates().copy()
print('После удаления дубликатов:', tabl.duplicated().sum())
print('Размер:', tabl.shape)
```

Рисунок 15 — Реализация подсчёта явных дубликатов

```
Явных дубликатов до удаления: 2
После удаления дубликатов: 0
Размер: (381, 7)
```

Рисунок 16 — Количество явных дубликатов до и после удаления

При проверке категорий обнаружены различия регистра COMEDY/comedy и опечатка dramaa. Жанры приведены к нижнему регистру, опечатка исправлена; коды стран очищены от случайных пробелов и приведены к верхнему регистру. После нормализации выполнена повторная проверка полностью совпадающих строк. Реализация и результаты представлены на рисунках 17–18.

```
print('Жанры до нормализации:', sorted(tabl['main_genre'].unique()))
print('Страны до нормализации:', sorted(tabl['main_production'].unique()))
tabl['main_genre'] = tabl['main_genre'].str.strip().str.lower().replace('dramaa', 'drama')
tabl['main_production'] = tabl['main_production'].str.strip().str.upper()
print('Жанры после нормализации:', sorted(tabl['main_genre'].unique()))
```

Рисунок 17 — Реализация замены неявных дубликатов

```
Жанры до нормализации: ['COMEDY', 'action', 'animation', 'comedy', 'crime', 'documentary', 'drama', 'dramaa',
'fantasy', 'horror', 'musical', 'romance', 'scifi', 'sports', 'thriller', 'war', 'western']
Страны до нормализации: ['AR', 'AU', 'BE', 'BR', 'CA', 'CD', 'CN', 'DE', 'DK', 'ES', 'FR', 'GB', 'HK', 'HU', 'ID',
'IE', 'IN', 'IT', 'JP', 'KH', 'KR', 'LT', 'MW', 'MX', 'NL', 'NO', 'NZ', 'PL', 'PS', 'TH', 'TR', 'UA', 'US', 'XX',
'ZA']
Жанры после нормализации: ['action', 'animation', 'comedy', 'crime', 'documentary', 'drama', 'fantasy', 'horror',
'musical', 'romance', 'scifi', 'sports', 'thriller', 'war', 'western']
Повторных строк после нормализации: 0
Итоговое число строк: 381
```

Рисунок 18 — Проверка на замену дубликатов

5. Проверка типов данных.

При проверке типов данных было обнаружено, что столбцы release_year и number_of_votes имеют тип float64, хотя содержащиеся в них значения являются целыми числами. Поэтому было принято решение привести данные столбцы к типу int с помощью метода astype(). Столбец score оставлен с типом float64, так как рейтинг фильма может содержать дробное значение. Реализация и результат изменения типов данных представлены на рисунках 19-20.

```
print(tabl.dtypes)

for column in ['release_year', 'number_of_votes']:
    assert (tabl[column] % 1 == 0).all(), f'В {column} обнаружена дробная часть'
    tabl[column] = tabl[column].astype(int)
print('Типы после преобразования:')
print(tabl.dtypes)
display(tabl.describe())
assert tabl.isna().sum().sum() == 0
assert tabl.duplicated().sum() == 0
```

Рисунок 19 — Реализация программы

```
title               object
release_year       float64
score              float64
number_of_votes    float64
duration             int64
main_genre          object
main_production     object
dtype: object
Типы после преобразования:
title               object
release_year         int64
score              float64
number_of_votes      int64
duration             int64
main_genre          object
main_production     object
dtype: object
```

	release_year	score	number_of_votes	duration
count	381.000000	381.000000	3.810000e+02	381.000000
mean	2010.997375	7.509186	1.362626e+05	123.530184
std	10.862659	0.445084	2.350996e+05	28.528329
min	1954.000000	6.900000	1.013900e+04	28.000000
25%	2008.000000	7.100000	2.043000e+04	104.000000
50%	2014.000000	7.400000	4.491700e+04	122.000000
75%	2018.000000	7.800000	1.534630e+05	139.000000
max	2022.000000	9.000000	2.268288e+06	229.000000

Рисунок 20 — Типы данных и статистика после очистки

После преобразования столбцы release_year и number_of_votes получили тип int64, что соответствует характеру содержащихся в них данных. Остальные типы данных изменять не потребовалось.

6. Группировка данных.

Задание 1. Группировка — жанр и количество фильмов каждого main_production.

Группировка выполняется с помощью метода groupby(), который позволяет объединять данные по выбранным признакам. В данном задании фильмы были сгруппированы по двум столбцам: main_genre — основной жанр и main_production — страна производства. С помощью метода size() было определено количество фильмов в каждой группе. Реализация программы и результат выполнения представлены на рисунках 21–22.

```
grouped_1 = tabl.groupby(['main_genre', 'main_production']).size()
with pd.option_context('display.max_rows', None):
    display(grouped_1.to_frame('Количество'))
print('Число групп:', len(grouped_1))
```

Рисунок 21 — Написание программы по группировке

		Количество
main_genre	main_production	
action	DE	1
	IN	2
	US	2
animation	JP	1
	US	2
comedy	AR	1
	AU	1
	CA	1
	ES	1
	FR	1
	GB	5
	IN	20
	JP	1
	NO	1
	NZ	1

```
Число групп: 93
```

Рисунок 22 — Фрагмент группировки по жанрам и странам

По результатам группировки было определено количество фильмов для каждой комбинации жанра и страны производства. Получено 93 группы. Результат показывает, что один и тот же жанр может быть представлен фильмами разных стран производства. В отчёте показан фрагмент; полная таблица выведена в ноутбуке.

Задание 2. Группировка — main_genre и количество фильмов по каждой стране производства main_production. Создать DataFrame. Переименовать столбец с количеством в count. Отсортировать по убыванию столбца count.

В данном задании необходимо выполнить группировку фильмов по жанру и стране производства, преобразовать результат в DataFrame, переименовать столбец с количеством фильмов в count и отсортировать данные по убыванию этого столбца. Реализация и выполнение программы представлены на рисунках 23-24.

```
grouped_2 = grouped_1.reset_index(name='count')
grouped_2 = grouped_2.sort_values('count', ascending=False)
with pd.option_context('display.max_rows', None):
    display(grouped_2)
```

Рисунок 23 — Код программы

	main_genre	main_production	count
50	drama	US	53
39	drama	IN	48
89	thriller	US	21
85	thriller	IN	21
16	comedy	US	21
11	comedy	IN	20
27	documentary	US	14
35	drama	GB	14
69	romance	IN	12
20	crime	IN	9
59	fantasy	US	8
22	crime	US	8
92	western	US	7
71	romance	US	6
10	comedy	GB	5

Рисунок 24 — Первые строки группировки, отсортированной по count

По результатам сортировки видно, какие сочетания жанра и страны производства представлены в наборе данных чаще всего. Наибольшее количество фильмов относится к жанру drama производства США — 53 фильма, а также Индии — 48 фильмов.

Задание 3. Сводная таблица pivot_table — средний рейтинг score фильмов по странам производства main_production. Отсортировать значения по убыванию рейтинга и округлить результат до одного знака после запятой.

Для определения среднего рейтинга фильмов по странам производства была создана сводная таблица с помощью метода pivot_table(). В качестве строк используется столбец main_production, а для столбца score вычисляется среднее значение. Полученный результат сортируется по убыванию рейтинга и округляется до одного знака после запятой. Реализация и результаты работы программы представлены на рисунках 25-26.

```
pivot_1 = tabl.pivot_table(
    index='main_production',
    values='score',
    aggfunc='mean'
)
pivot_1 = pivot_1.sort_values('score', ascending=False).round(1)
display(pivot_1)
```

Рисунок 25 — Реализация программы по созданию сводной таблицы

	score
main_production	
CD	8.2
UA	8.1
ZA	8.1
TR	7.8
NZ	7.8
MX	7.7
TH	7.6
MW	7.6
IN	7.6
GB	7.6
AU	7.6
ES	7.6
AR	7.5
HK	7.5
PS	7.5

Рисунок 26 — Страны с наиболее высоким средним рейтингом

По результатам сводной таблицы видно, что наибольший средний рейтинг имеют фильмы производства CD — 8,2. Далее следуют фильмы производства UA и ZA со средним рейтингом 8,1. Средний рейтинг фильмов производства Индии и Великобритании составляет 7,6. При этом результаты следует учитывать с осторожностью, так как количество фильмов для разных стран в наборе данных может различаться.

Задание 4. Сводная таблица pivot_table — медианный рейтинг score фильмов по жанрам main_genre — столбцы и странам производства main_production — строки. Отсортировать по возрастанию main_production.

Для анализа медианного рейтинга фильмов была построена сводная таблица. В строках располагаются страны производства, в столбцах — жанры фильмов, а в

ячейках рассчитывается медианное значение рейтинга. Реализация и результат работы программы представлен на рисунках 27-28.

```
pivot_2 = tabl.pivot_table(
    index='main_production',
    columns='main_genre',
    values='score',
    aggfunc='median'
).sort_index()
with pd.option_context('display.max_rows', None, 'display.max_columns', None):
    display(pivot_2)
```

Рисунок 27 — Код программы

main_genre	comedy	crime	documentary	drama	thriller
main_production					
CD	NaN	NaN	NaN	NaN	NaN
GB	8.00	7.40	9.0	7.15	7.60
IN	7.60	7.40	NaN	7.60	7.50
JP	7.60	NaN	NaN	7.40	NaN
UA	NaN	NaN	8.1	NaN	NaN
US	7.30	7.35	7.6	7.40	7.30
ZA	NaN	NaN	8.1	NaN	NaN

Рисунок 28 — Фрагмент сводной таблицы медианных рейтингов

При выполнении данного задания была создана сводная таблица медианного рейтинга фильмов по жанрам и странам производства. По результатам видно, что для некоторых сочетаний жанра и страны указано значение NaN. Это связано с тем, что в наборе данных отсутствуют фильмы соответствующего жанра для данной страны производства. На рисунке 28 показаны выбранные страны и жанры для читаемости; полная таблица доступна в ноутбуке.

По полученным данным можно сравнить медианные рейтинги фильмов разных жанров. Например, медианный рейтинг драм производства Индии составляет 7,6, а США — 7,4. Для комедий медианный рейтинг составляет 7,6 для Индии и 7,3 для США. Таким образом, сводная таблица позволяет сравнить типичные рейтинги фильмов разных жанров в зависимости от страны производства.

ВЫВОД

В ходе лабораторной работы был проведён предварительный анализ набора данных movies.csv, содержащего информацию о фильмах. Исходный набор содержал

389 строк и 7 столбцов. В процессе предварительной обработки были выявлены и удалены 6 строк с пропущенными значениями и 2 явных дубликата. Также были устранены неявные дубликаты в столбце main_genre: значения приведены к единому регистру, а ошибочная запись dramaa заменена на drama. Типы данных столбцов release_year и number_of_votes были изменены на целочисленные. После очистки набор содержит 381 запись. По результатам группировок установлено, что наиболее многочисленными являются драмы производства США — 53 фильма и Индии — 48 фильмов. С помощью сводных таблиц были рассчитаны средние рейтинги по странам производства и медианные рейтинги по жанрам и странам. Таким образом, исходные данные были очищены, приведены к согласованному виду и подготовлены для дальнейшего анализа. При сравнении средних и медиан учитывалось, что группы отличаются по размеру. NaN в сводной таблице обозначает отсутствующее сочетание страны и жанра, а не оставленный пропуск в исходных строках.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Лабораторная работа 1. Предварительный анализ данных : методические материалы по дисциплине «Введение в анализ данных». — 98 с. — Общие требования: с. 1–3; задания варианта 13: с. 58–59. Набор данных movies.csv.

2. Ссылка на блокнот Google Colab

https://colab.research.google.com/drive/1Ibcy-yV4px9AFjouOZ0a5MDD6S3VL4HY?usp=sharing