ЛАБОРАТОРНАЯ РАБОТА №2

Полный разбор кода, выборок и диаграмм

Исследовательский анализ movies.csv • Вариант 13

Курбатов М. П. • Группа 4417

Учебное пособие для понимания работы и подготовки к защите. Основано на исправленном ноутбуке ЛР2_Курбатов_4417_вариант13.ipynb и исходном movies.csv. Все числа ниже пересчитаны по предоставленным данным.

• 26 кодовых блоков: разобраны все 194 непустые строки и параметры.

• 18 иллюстраций результатов из работы, 26 изображений кода с номерами строк.

• Определения, формулы, происхождение выборок и типичные вопросы преподавателя.

• Дополнительные схемы помогают читать boxplot, логарифмическую ось и гистограммы.

Изображения кода в пособии сформированы из текста ноутбука с подсветкой синтаксиса; это учебные листинги, а не скриншоты интерфейса Colab. Графики результатов взяты из выполненной работы.

Версия: 10 ноября 2026 года.

Содержание

Содержание 2

1. Как пользоваться этим пособием 4

2. Данные и происхождение выборок 4

3. Статистические понятия и формулы 6

3.1. Среднее, медиана, дисперсия и стандартное отклонение 6

3.2. Квартили и интерполяция 7

3.3. Ковариация и корреляция 7

3.4. Частоты, гистограмма и KDE 8

3.5. Логарифмическая ось 9

3.6. Среднее по группам и круговая диаграмма 9

3.7. Boxplot: квартиль, граница, ус и выброс 10

4. Словарь понятий и различий 11

5. Последовательный разбор всех строк программы 15

5.1. Блок 1: Импорт и чтение CSV 16

5.2. Блок 2: Первичная структура таблицы 17

5.3. Блок 3: Статистика исходных данных 18

5.4. Блок 4: Очистка и нормализация 19

5.5. Блок 5: Повторная проверка после очистки 22

5.6. Блок 6: Матрица диаграмм рассеяния 24

5.7. Блок 7: Рассеяние по шести жанрам 26

5.8. Блок 8: Четыре гистограммы 28

5.9. Блок 9: Численная проверка распределений 29

5.10. Блок 10: Корреляционная матрица и heatmap 30

5.11. Блок 11: Ковариационная матрица 32

5.12. Блок 12: Вывод отдельных корреляций . . . 33
5.13. Блок 13: Вариант 13: страны и жанры с 2020 года . . . 33
5.14. Блок 14: Табличное подтверждение countplot . . . 35
5.15. Блок 15: Вариант 13: средние голоса после 2010 года . . . 36
5.16. Блок 16: Проверка максимумов и минимумов . . . 38
5.17. Блок 17: Вариант 13: доли фильмов по годам . . . 39
5.18. Блок 18: Проверка процентов . . . 41
5.19. Блок 19: Hexbin: длительность и рейтинг . . . 41
5.20. Блок 20: Boxplot количества голосов . . . 43
5.21. Блок 21: Расчёт IQR, границы и уса . . . 45
5.22. Блок 22: Категоризация рейтинга и boxplot . . . 46
5.23. Блок 23: Проверка численности уровней . . . 48
5.24. Блок 24: Boxplot рейтинга по восьми жанрам . . . 49
5.25. Блок 25: Boxplot длительности по восьми странам . . . 51
5.26. Блок 26: Численность и медианы категорий . . . 53
6. Численные результаты, которые полезно знать . . . 53
6.1. Среднее число голосов по годам . . . 54
6.2. Численность и медианы жанров . . . 54
6.3. Численность и медианы стран . . . 55
6.4. Уровни рейтинга . . . 55
7. Типичные ошибки объяснения и корректные ответы . . . 56
8. Вопросы преподавателя и образцы ответов . . . 56
9. Изменения кода, которые могут попросить на защите . . . 59
10. Готовый связный рассказ о работе . . . 60
11. Проверочный список перед защитой . . . 60
12. Основание разбора и границы интерпретации . . . 61

1. Как пользоваться этим пособием

Сначала прочитайте разделы о данных, выборках и статистических понятиях. Затем переходите к последовательному разбору 26 блоков программы. В каждом блоке есть цель, входные данные, изображение кода, пояснения ко всем непустым строкам, результаты и рекомендации по чтению соответствующего рисунка.

Номера блоков 1–26 соответствуют порядку кодовых ячеек, а не номерам рисунков отчёта. Внутри каждого изображения кода строки нумеруются заново. Пустые строки разделяют фрагменты визуально и не выполняют вычислений; закрывающие скобки тоже объясняются.

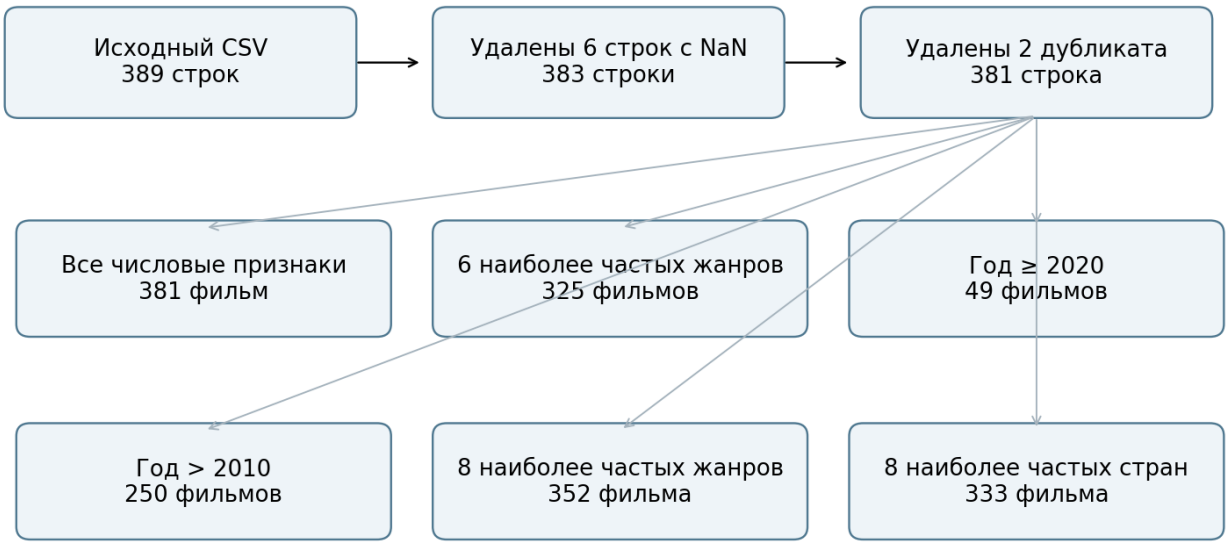
В исправленном отчёте 18 рисунков. В более старой версии их было 17: таблица статистики после очистки добавлена как рисунок 5. Здесь используется нумерация исправленного отчёта.

Цель ЛР2 — описать данные, распределения и взаимосвязи. Здесь не строится модель машинного обучения, не прогнозируется рейтинг и нет разделения train/test. Выборка в этом пособии — набор строк для конкретного анализа, а не обучающая выборка.

2. Данные и происхождение выборок

Признак	Определение	Как используется
title	Название фильма	Текстовое описание записи; не включается в числовую корреляцию.
release_year	Год выхода	Дискретный числовой признак; фильтры по годам и распределение.
score	Рейтинг	Числовая оценка; гистограммы, связи и сравнение групп.
number_of_votes	Количество голосов	Дискретный счётчик; не путать с рейтингом и количеством фильмов.
duration	Продолжительность, минуты	Числовой признак для распределения и сравнения стран.
main_genre	Основной жанр	Номинальная категория; частоты и групповые распределения.
main_production	Основная страна производства	Номинальная категория; не полный список стран совместного производства.

Одна строка — запись о фильме. Полное совпадение всех столбцов рассматривается как явный дубликат. Совпадение одного названия не является достаточным основанием удалить запись: одинаковые названия могут относиться к разным фильмам или версиям.



Фильтры создают поднаборы для графиков; основной df не заменяется ими.

Схема выборок: поднаборы ответвляются от очищенного df, а не заменяют его.

Анализ	Условие	Записей
До обработки	Весь исходный CSV	389
После удаления пропусков	Нет NaN ни в одном столбце	383
Основной анализ	Удалены ещё 2 полных дубликата	381
Рассеяние по жанрам	6 самых частых жанров	325
Задания 1 и 3 варианта	release_year ≥ 2020	49
Задание 2 варианта	release_year > 2010	250
Boxplot по жанрам	8 самых частых жанров	352
Boxplot по странам	8 самых частых стран	333

Отбор топ-категорий сделан ради читаемости графиков. Это не случайная выборка и не выбор лучших по рейтингу фильмов. Из полного df не удаляются остальные категории. После фильтрации по стране или жанру оцениваются именно выбранные группы.

Способ формирования исходного CSV неизвестен. Кроме того, рейтинги ограничены диапазоном 6,9–9,0. Нельзя автоматически распространять выводы на все фильмы и на мировое кинопроизводство. Термин «популярность» в этой работе используется лишь как интерпретация числа голосов, а не как измерение кассовых сборов.

3. Статистические понятия и формулы

3.1. Среднее, медиана, дисперсия и стандартное отклонение

Среднее — сумма значений, делённая на их количество. Оно использует каждое наблюдение, но чувствительно к очень большим и маленьким значениям.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

n — число непустых наблюдений, xi — значение признака, x̄ — среднее.

Медиана — центральное значение после сортировки. При нечётном числе строк берётся один центральный элемент, при чётном — среднее двух центральных. Она обычно устойчивее к отдельным экстремальным наблюдениям, чем среднее.

$$Me = x_{((n+1)/2)} \quad (n \text{ odd})$$

Скобки в индексе обозначают позицию в отсортированной последовательности.

$$Me = \frac{x_{(n/2)} + x_{(n/2+1)}}{2} \quad (n \text{ even})$$

При чётном количестве наблюдений центральных элементов два.

После очистки n = 381, поэтому медиана голосов — 191-й элемент отсортированного списка, равный 44 917. Среднее число голосов равно 136 262,61. Большая разница возникает из-за правого хвоста распределения, а не из-за ошибки формулы.

Дисперсия — средний квадрат отклонения от среднего с соответствующей нормировкой. Стандартное отклонение — корень дисперсии. В pandas describe/std/cov используется выборочная нормировка n−1. Дисперсия измеряется в квадрате исходных единиц, стандартное отклонение — в исходных единицах.

$$s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2, \qquad s = \sqrt{s^2}$$

Выборочная дисперсия s² и стандартное отклонение s.

Почему n−1: среднее оценено по тем же наблюдениям, а сумма отклонений от него равна нулю, поэтому свободных отклонений n−1. При независимых одинаково распределённых наблюдениях эта поправка даёт несмещённую оценку дисперсии. Это свойство формулы не доказывает, что наш CSV является случайной выборкой; само стандартное отклонение также не становится автоматически несмещённой оценкой.

Среднее 123,53 минуты и стандартное отклонение длительности 28,53 минуты не означают, что все фильмы лежат в интервале среднее ± стандартное отклонение. Также близость среднего и медианы не доказывает нормальность распределения.

3.2. Квартили и интерполяция

Q1, Q2 и Q3 — квантили уровней 0,25; 0,50 и 0,75. Q2 совпадает с медианой. Квартили описывают положение значений, а не задают три группы одинаковой ширины. Центральная половина распределения находится между Q1 и Q3.

$$h = (n-1)p, \quad k = \lfloor h \rfloor, \quad Q(p) = x_{(k+1)} + (h-k)[x_{(k+2)} - x_{(k+1)}]$$

Линейная интерполяция для внутреннего промежутка отсортированного ряда.

В формуле p — уровень квантиля, h — дробная позиция с нулевого индекса, k — её целая часть. Если h целое, берётся элемент x(h+1); при p = 1 — последний элемент. Для n = 381 позиции квартилей целые: 96-я, 191-я и 286-я при нумерации с единицы.

3.3. Ковариация и корреляция

$$s_{xy} = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})$$

Выборочная ковариация измеряет совместное изменение двух признаков.

При одинаковых знаках отклонений от средних произведение положительно; при противоположных — отрицательно. Ковариация зависит от единиц измерения. Поэтому 36 тысяч для пары «рейтинг — голоса» не означают автоматически более сильную связь, чем −0,7 для другой пары.

$$r_{xy} = \frac{\sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n} (x_i - \bar{x})^2 \sum_{i=1}^{n} (y_i - \bar{y})^2}} = \frac{s_{xy}}{s_x s_y}$$

Корреляция Пирсона — нормированная ковариация; она безразмерна.

Корреляция лежит от −1 до +1. Знак задаёт направление линейной связи, модуль — её выраженность. Границы «слабая/умеренная/сильная» условны. Почти нулевой коэффициент не исключает нелинейной зависимости. Корреляция не доказывает причинность; в этой работе также не рассчитывались p-value и доверительные интервалы.

Пара признаков	r Пирсона	Корректная интерпретация
Рейтинг — голоса	0,347352	Положительная, но не сильная линейная связь.
Год — голоса	−0,212222	Слабая обратная линейная связь.
Год — рейтинг	−0,152453	Слабая обратная связь.

Пара признаков	r Пирсона	Корректная интерпретация
Длительность — рейтинг	0,127034	Слабая прямая связь.
Год — длительность	−0,103095	Очень слабая обратная связь.
Голоса — длительность	0,102842	Очень слабая прямая связь.

В корреляционной матрице диагональ равна 1: непостоянный признак идеально связан с самим собой. В ковариационной матрице на диагонали находятся дисперсии. Например, дисперсия длительности около 813,87, а её корень равен 28,53 — значению std из describe().

3.4. Частоты, гистограмма и KDE

$$N_j = \sum_{i=1}^{n} \mathbf{1}(x_i \in B_j), \quad p_j = \frac{N_j}{n}, \quad \Delta = \frac{x_{max} - x_{min}}{m}$$

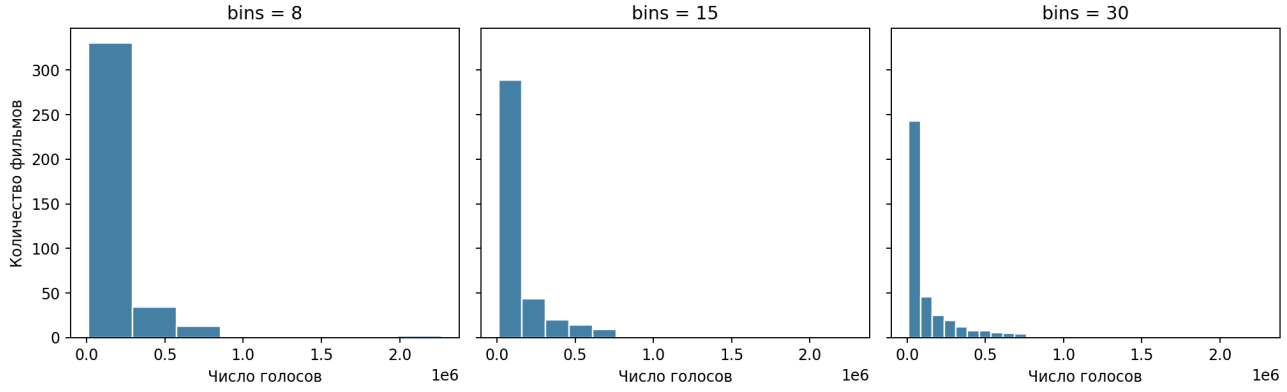
Nj — количество наблюдений в интервале Bj; pj — относительная частота; m — число равных интервалов.

На вашей гистограмме по вертикали count — количество фильмов. Это не вероятность, не число голосов и не средний рейтинг. Для 15 равных интервалов голосов ширина составляет примерно 150 543,27 голоса. Большой первый столбец частично объясняется тем, что большинство значений лежит в нижней части большого общего диапазона.

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - x_i}{h}\right), \quad K(u) = \frac{e^{-u^2/2}}{\sqrt{2\pi}}$$

Ядерная оценка плотности; h — параметр сглаживания, K — ядро.

Гауссовское ядро добавляет около каждого наблюдения гладкий вклад. Сумма вкладов формирует плавную кривую. Ширина h определяет сглаживание; в ноутбуке она вручную не подбиралась. При шкале count Seaborn масштабирует KDE под гистограмму. Это описание распределения одного признака, а не линия регрессии между двумя признаками.



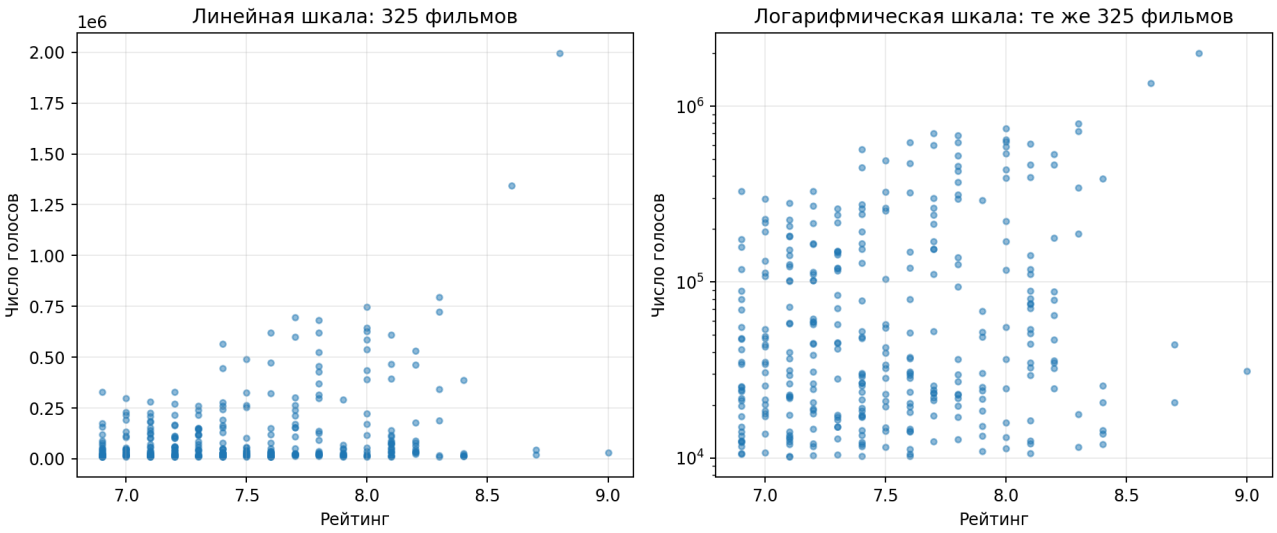
Один и тот же набор из 381 фильма при 8, 15 и 30 интервалах.

Пятнадцать интервалов — выбранный визуальный компромисс, не математически доказанный универсальный оптимум. Малое bins скрывает детали, большое создаёт узкие нестабильные столбцы. Параметр kde=True не меняет исходные наблюдения.

3.5. Логарифмическая ось

$$y' = \log_{10} y, \qquad \log_{10}(10y) - \log_{10} y = 1$$

Для обычной логарифмической оси равные расстояния отражают одинаковые отношения, например ×10.



Смена шкалы не меняет выборку: на обеих диаграммах те же 325 фильмов.

Расстояния между 10 тысячами и 100 тысячами и между 100 тысячами и миллионом одинаковы на log-оси, хотя арифметические разности различны. Команда yscale("log") меняет отображение, а не записывает log в df. Корреляция в работе всё равно считается между score и исходным number_of_votes. Для неположительных значений обычная log-ось проблемна; в этом CSV все голоса положительны.

3.6. Среднее по группам и круговая диаграмма

$$\overline{V}_t = \frac{1}{n_t} \sum_{i:\ year_i = t} V_i$$

nt — число фильмов данного года, Vi — число голосов одного фильма.

В 2012 году в подвыборке 12 фильмов: 3 926 524 голоса / 12 = 327 210,33. В 2022 году 5 фильмов: 151 151 / 5 = 30 230,20. Каждая точка рисунка 12 отчёта — агрегат года. Нельзя путать максимум среднего с максимальным количеством фильмов.

$$p_t = 100\frac{n_t}{N}\%, \qquad \alpha_t = 360^\circ\frac{n_t}{N}$$

Для сектора доля и угол вычисляются из количества фильмов, не из суммы голосов.

Год	Количество	Доля	Угол сектора
2020	19	38,8%	≈139,6°
2021	25	51,0%	≈183,7°
2022	5	10,2%	≈36,7°
Всего	49	100%	360°

3.7. Boxplot: квартиль, граница, ус и выброс

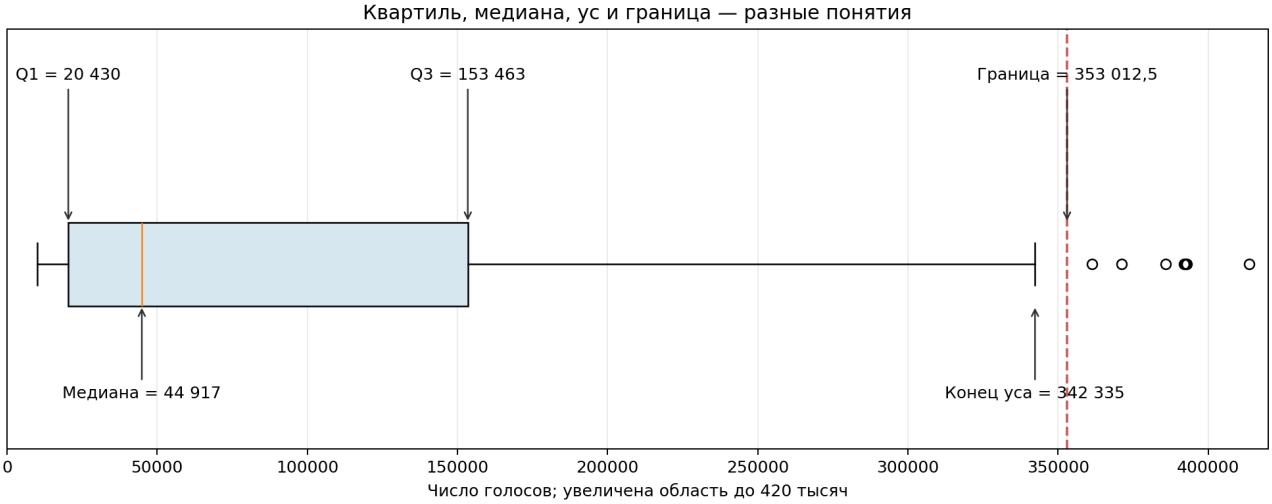
$$IQR = Q_3 - Q_1, \quad L = Q_1 - 1.5IQR, \quad U = Q_3 + 1.5IQR$$

IQR — межквартильный размах; L и U — расчётные границы по правилу 1,5 IQR.

$$W_L = \min\{x_i : x_i \geq L\}, \qquad W_U = \max\{x_i : x_i \leq U\}$$

Усы заканчиваются на существующих наблюдениях внутри расчётных границ.

Величина	Значение для number_of_votes
Q1	20 430
Медиана	44 917
Q3	153 463
IQR = Q3 − Q1	133 033
Нижняя расчётная граница	−179 119,5
Верхняя расчётная граница	353 012,5
Нижний ус	10 139
Верхний ус	342 335
Наблюдений выше верхней границы	39 из 381, около 10,24%



Увеличенная область фактического boxplot: граница и конец уса не совпадают.

В использованном boxplot параметр whis явно не задан: применяется стандартное правило 1,5 IQR. Если изменить whis, положение усов и число отмеченных точек изменятся, хотя сами наблюдения останутся теми же.

Ящик охватывает центральные 50% значений, линия внутри — медиана. Усы не обязаны быть симметричными и не обязаны совпадать с min/max всего столбца. Отдельные точки — значения за границами. Они не удаляются самим boxplot и не признаются ошибками автоматически.

Дробная граница 353 012,5 не противоречит целочисленным голосам: это вычисленная величина. Отрицательная нижняя граница также не означает наличие отрицательных голосов. Реальный минимум равен 10 139.

4. Словарь понятий и различий

DataFrame и Series

DataFrame — двумерная таблица; Series — одномерный столбец с индексом. df["score"] возвращает Series, df[["score"]] — DataFrame.

Наблюдение и признак

Наблюдение — строка о фильме; признак — его характеристика в столбце. Число строк не равно числу голосов.

Генеральная совокупность и выборка

Совокупность — все объекты, о которых хотят сделать вывод; выборка — наблюдаемые записи. Для этого CSV схема отбора неизвестна, поэтому репрезентативность не установлена.

Случайная выборка и фильтрация

Случайная выборка предполагает механизм случайного отбора; фильтрация оставляет строки по условию. Топ жанров и фильмы с 2020 года не являются случайными подвыборками.

Номинальный и порядковый признак

Страна и жанр номинальные: порядка нет. score_level порядковый: низкий < средний < высокий, но расстояния между уровнями не обязаны быть равными.

Дискретный и непрерывный

Голоса — дискретный счётчик, год — дискретное значение. Рейтинг измеряется числом и здесь имеет шаг 0,1; длительность в CSV целая. Тип float64 сам по себе не делает признак непрерывным по смыслу.

NaN и 0

NaN — отсутствующее значение; ноль — конкретное числовое наблюдение. Нельзя без основания заменять пропуски нулями.

Пустая ячейка и строка с пропуском

В строке может быть несколько пропусков. В файле 12 пустых ячеек в 6 строках, поэтому эти числа различаются.

Явный и неявный дубликат

Явный дубликат — полное повторение записи. В работе под неявными понимают разные написания одной категории: COMEDY/comedy, dramaa/drama. Повторение жанра у разных фильмов нормально.

Нормализация категорий и масштабирование

strip/lower/replace унифицируют написание категорий. Масштабирование меняет шкалу чисел, например StandardScaler. В этой ЛР стандартизации нет.

Среднее и медиана

Среднее использует сумму всех значений; медиана — центральную позицию после сортировки. Для правого хвоста среднее часто больше медианы.

Дисперсия и стандартное отклонение

Дисперсия измеряется в квадрате единиц, std — в исходных. Оба описывают разброс; ни одно само по себе не доказывает форму распределения.

Квантиль и квартиль

Квантиль задаётся произвольным уровнем p. Квартили — специальные уровни 0,25; 0,50; 0,75.

Частота и относительная частота

Частота — количество записей; относительная частота — доля от общего количества. Процент — доля, умноженная на 100.

Гистограмма и столбчатая диаграмма

Гистограмма группирует числовую ось в интервалы; countplot сравнивает категории. Высота в обоих случаях может быть количеством, но оси и способ группировки различаются.

Scatter и hexbin

Scatter показывает каждую точку; hexbin агрегирует их количество внутри областей. Hexbin удобен при наложении наблюдений.

KDE и регрессия

KDE описывает распределение одного признака; регрессия моделирует зависимость целевой переменной от других. Кривая на гистограмме здесь не регрессия.

Корреляция и ковариация

Обе описывают линейную совместную изменчивость. Ковариация зависит от масштаба, корреляция нормирована и безразмерна.

Связь и причинность

Совместное изменение не доказывает, что один признак вызывает другой. Возможны общие причины, особенности отбора и обратное направление связи.

Группа и сводная таблица

groupby объединяет записи по ключам. pivot_table выполняет группировку и агрегацию с табличным размещением результата.

size и count

size считает строки группы, count — непустые значения выбранного признака. После полной очистки для заполненного признака они совпадают.

max и idxmax

max возвращает максимальное значение; idxmax — метку строки этого значения. Здесь это среднее голосов и год соответственно.

sort_index и sort_values

Первое сортирует метки, например годы; второе — сами количества или средние. Для хронологии нужна сортировка по индексу.

head и случайный отбор

head(n) берёт первые n строк в текущем порядке; random-выбор потребовал бы sample().

Логическая маска и индекс

Маска — True/False для каждой строки; индекс — метки строк. После удаления данных метки могут иметь пропуски, поэтому длину считают len/shape.

Присваивание и сравнение

= присваивает значение переменной; == сравнивает два значения; >= и > различаются включением границы.

Метод и атрибут

Метод вызывается со скобками: info(), head(). Атрибут читается без них: columns, shape, index, values.

Figure и Axes

Figure — всё изображение; Axes — отдельная область с осями. Четыре Axes могут находиться внутри одной Figure.

Параметр изображения и параметр данных

figsize, alpha и rotation оформляют график; фильтр data и число bins определяют представление данных. alpha не выбирает 60% строк.

Выброс и ошибка

Выброс — необычное по выбранному правилу наблюдение; ошибка — неверная запись. Эти понятия не тождественны.

Граница и конец уса

Граница рассчитывается как квартиль ±1,5 IQR; ус заканчивается на крайнем имеющемся наблюдении внутри границ.

Статистика и вывод

Статистика — рассчитанное число. Вывод — его интерпретация с учётом выборки и ограничений. Число само не устанавливает причинность или универсальность.

Асимметрия распределения

Правосторонняя асимметрия означает длинный хвост в сторону больших значений, левосторонняя — в сторону малых. Среднее часто смещается к хвосту. Само превышение среднего над медианой — полезный признак, но форму лучше подтверждать графиком.

Робастность

Устойчивость показателя к отдельным экстремальным значениям. Медиана обычно устойчивее среднего; это не означает, что среднее ошибочно или что медиана отвечает на любой вопрос лучше.

Рейтинг и число голосов

score — готовая оценка в исходном CSV, number_of_votes — количество проголосовавших. Формула формирования исходного score не предоставлена; в работе этот рейтинг не восстанавливается из отдельных голосов.

Параметр и аргумент

Параметр — именованная настройка функции, например bins. Аргумент — переданное значение, например 15 в bins=15. Запись figsize=(12, 8) передаёт кортеж из двух чисел.

Функция и метод

Функция вызывается по имени, например len(df). Метод связан с объектом: df.info(). Один и тот же результат может передаваться следующему методу в цепочке.

Группировка и агрегация

Группировка определяет, какие строки относятся к одной группе. Агрегация сводит значения группы к показателю: mean, median, count, sum. Одно не заменяет другое.

Фильтрация и сортировка

Фильтр отбирает строки по условию. Сортировка меняет порядок, но сама по себе не сокращает число записей. head после сортировки уже ограничивает вывод или поднабор.

Процент и процентиль

Процент — доля от целого, умноженная на 100. Процентиль — порог распределения: например 75-й процентиль равен Q3. Это разные типы величин.

Плотность и количество

Количество — число наблюдений в интервале. Плотность нормируется на ширину интервала и объём выборки, её интеграл равен 1. На вашей гистограмме count, а KDE масштабируется библиотекой под неё.

axis=0 и axis=1

При свёртке DataFrame axis=0 означает вычисление вдоль строк для каждого столбца; axis=1 — вычисление вдоль столбцов для каждой строки. Поэтому isna().any(axis=1) ищет пропуски внутри строки.

print, display и возвращаемое значение

print делает текстовый вывод, display показывает форматированную таблицу, а возврат функции может использоваться дальше. info() сам печатает информацию и возвращает None; describe() возвращает таблицу.

Индекс и номер позиции

Индекс — метка строки, позиция — её порядковое место. loc работает с метками, iloc — с позициями. После удаления строк индекс может иметь пропуски; это не потеря непрерывности данных.

Скобки и цепочки вызовов

Круглые скобки вызывают функцию или группируют выражение; квадратные выбирают столбец/строки или создают список; фигурные могут создавать словарь или подставлять выражение в f-строке. Цепочка выполняется последовательно слева направо.

Обычная и f-строка

Обычная строка хранит текст. В f-строке выражение внутри фигурных скобок подставляется в текст: например имя column в заголовок графика. Префикс f не влияет на статистические значения.

5. Последовательный разбор всех строк программы

Ниже идут все 26 кодовых блоков из исправленного ноутбука. Изображения содержат полный код с исходной нумерацией строк внутри ячейки. Каждый непустой элемент сопровождается пояснением; пустые строки не исполняются. Пояснения относятся к фактическому коду, а не к другой версии работы.

5.1. Блок 1: Импорт и чтение CSV

Данные и выборка: Исходные 389 строк, 7 столбцов.

Что должно получиться: Созданы df и initial_rows; показаны первые пять строк.

```
1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4 import seaborn as sns
5
6 file_path = '/content/movies.csv'  # Укажите путь к своему CSV.
7 df = pd.read_csv(file_path, sep=';')
8 initial_rows = len(df)
9 df.head()  # первые строки
```

Код 1. Полная ячейка с нумерацией строк.

Построчный разбор

`01 import pandas as pd`

Подключает pandas под коротким именем pd. Библиотека читает CSV и работает с DataFrame и Series.

`02 import numpy as np`

Подключает NumPy как np. Прямых вызовов np в этом ноутбуке нет: импорт не влияет на результаты и не является обязательным.

`03 import matplotlib.pyplot as plt`

Подключает интерфейс pyplot библиотеки Matplotlib. Через plt создаются фигуры, подписи, легенды и выводятся изображения.

`04 import seaborn as sns`

Подключает Seaborn как sns. Эта библиотека строит статистические графики на основе Matplotlib.

`06 file_path = '/content/movies.csv' # Укажите путь к своему CSV.`

Сохраняет путь к CSV в строковой переменной. /content — рабочая папка Colab. Комментарий после # не выполняется.

`07 df = pd.read_csv(file_path, sep=';')`

Читает таблицу один раз. Первый аргумент — путь; sep=";" означает разделение столбцов точкой с запятой. Результат DataFrame присваивается df.

`08 initial_rows = len(df)`

len(df) возвращает число строк. initial_rows запоминает исходные 389 строк, чтобы последующие удаления можно было проверить.

`09 df.head() # первые строки`

Возвращает первые пять строк: аргумент n не указан, поэтому используется значение по умолчанию 5. В последней строке ячейки Colab автоматически отображает результат.

Результат: рисунок 1 в отчёте

	title	release_year	score	number_of_votes	duration	main_genre	main_production
0	David Attenborough: A Life on Our Planet	2020.0	9.0	31180.0	83	documentary	GB
1	Inception	2010.0	8.8	2268288.0	148	scifi	GB
2	Forrest Gump	1994.0	8.8	1994599.0	142	drama	US
3	Anbe Sivam	2003.0	8.7	20595.0	160	comedy	IN
4	Bo Burnham: Inside	2021.0	8.7	44074.0	87	comedy	US

Рисунок 1 из выполненной ЛР2.

Как читать и объяснять

• Проверьте, что семь столбцов разделены правильно и значения соответствуют названиям.

• Первые строки не случайны: по ним нельзя оценить все частоты или всё распределение.

Краткий ответ на защите: Созданы df и initial_rows; показаны первые пять строк.

5.2. Блок 2: Первичная структура таблицы

Данные и выборка: Все исходные строки; заполненность считается по каждому столбцу.

Что должно получиться: У title 384 non-null; у года 387; у score 386. Число пропусков = 389 − non-null.

```
1 df.info()  # информация о датасете
```

Код 2. Полная ячейка с нумерацией строк.

Построчный разбор

```
01 df.info() # информация о датасете
```

Выводит структуру df: 389 строк, названия и типы столбцов, число непустых значений, приблизительную память. Метод печатает информацию и возвращает None; дополнительный print не нужен.

Результат: рисунок 2 в отчёте

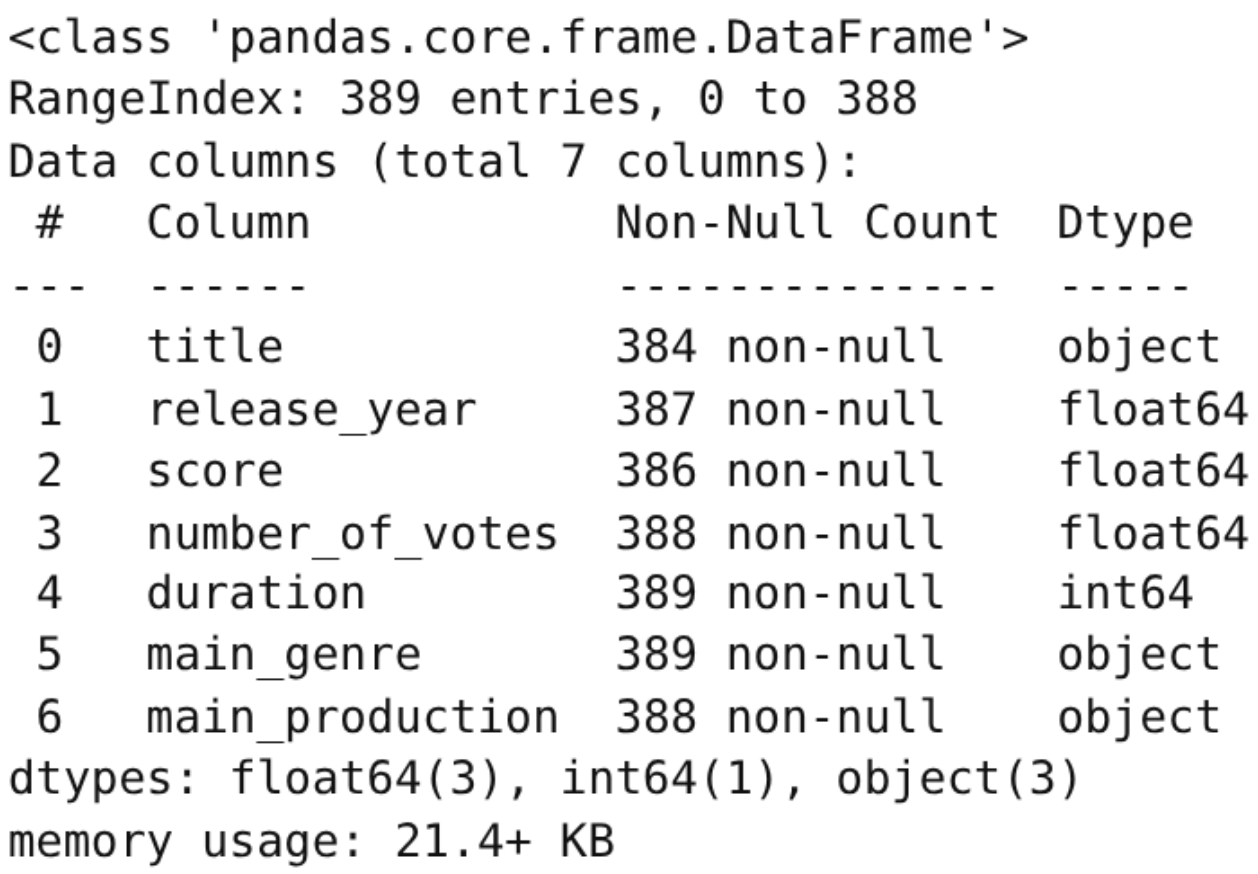


Рисунок 2 из выполненной ЛР2.

Как читать и объяснять

• Сравните каждое non-null с общим числом строк.

• float64 у года объясняется наличием пропусков, но после очистки тип нужно привести к целому.

Краткий ответ на защите: У title 384 non-null; у года 387; у score 386. Число пропусков = 389 − non-null.

5.3. Блок 3: Статистика исходных данных

Данные и выборка: Числовые значения до удаления пропусков и дублей.

Что должно получиться: count различается между столбцами; это ещё не финальные характеристики очищенного набора.

```
1 df.describe()  # описательная статистика
```

Код 3. Полная ячейка с нумерацией строк.

Построчный разбор

```
01 df.describe() # описательная статистика
```

Возвращает описательную статистику числовых столбцов до очистки. count — непустые значения, mean — среднее, std — выборочное стандартное отклонение, 25/50/75% — квартили.

Результат: рисунок 3 в отчёте

	release_year	score	number_of_votes	duration
count	387.000000	386.000000	3.880000e+02	389.000000
mean	2010.976744	7.512176	1.391523e+05	123.352185
std	10.805726	0.443870	2.365279e+05	28.304800
min	1954.000000	6.900000	1.013900e+04	28.000000
25%	2007.500000	7.100000	2.055375e+04	104.000000
50%	2014.000000	7.400000	4.606950e+04	122.000000
75%	2018.000000	7.800000	1.551585e+05	139.000000
max	2022.000000	9.000000	2.268288e+06	229.000000

Рисунок 3 из выполненной ЛР2.

Как читать и объяснять

• Смотрите count, затем mean/median, std и min/max.

• Не подменяйте статистикой до очистки характеристики окончательных 381 наблюдения.

Краткий ответ на защите: count различается между столбцами; это ещё не финальные характеристики очищенного набора.

5.4. Блок 4: Очистка и нормализация

Данные и выборка: 389 → 383 → 381 запись.

Что должно получиться: Удалены 6 строк с пропусками и 2 дубля, категории и типы исправлены.

```
print('Пропуски до обработки:')
print(df.isna().sum())

print('\nДубликаты до обработки:', df.duplicated().sum())

missing_rows = df.isna().any(axis=1).sum()
df = df.dropna().copy()  # удаляем пропуски
df = df.drop_duplicates().copy()  # удаляем дубликаты

df['main_genre'] = df['main_genre'].str.strip().str.lower()  # жанры
df['main_genre'] = df['main_genre'].replace('dramaa', 'drama')  # исправляем опечатку
df['main_production'] = df['main_production'].str.strip().str.upper()  # страны
df['release_year'] = df['release_year'].astype(int)  # год в int
df['number_of_votes'] = df['number_of_votes'].astype(int)  # голоса в int
print('\nРазмер после обработки:', df.shape)
removed_rows = initial_rows - len(df)
print('\nПропуски после обработки:')
print(df.isna().sum())
print('\nДубликаты после обработки:', df.duplicated().sum())
```

Код 4. Полная ячейка с нумерацией строк.

Построчный разбор

`01 print('Пропуски до обработки:')`

Печатает поясняющую строку. Данные не меняет.

`02 print(df.isna().sum())`

isna() превращает каждую ячейку в признак пропуска True/False; sum() по умолчанию складывает по строкам и даёт число пропусков в каждом столбце.

`04 print('\nДубликаты до обработки:', df.duplicated().sum())`

duplicated() отмечает полные повторные строки, кроме первого экземпляра; sum() считает их. Здесь их 2. Символ \n начинает вывод с новой строки.

`06 missing_rows = df.isna().any(axis=1).sum()`

any(axis=1) проверяет все столбцы каждой строки: есть ли хотя бы один пропуск. sum() считает такие строки: 6. Это отличается от 12 пустых ячеек.

`07 df = df.dropna().copy() # удаляем пропуски`

dropna() без параметров удаляет строки с любым пропуском. copy() создаёт отдельную копию результата. Присваивание обновляет df: 389 → 383 строки.

`08 df = df.drop_duplicates().copy() # удаляем дубликаты`

Удаляет полные дубликаты, сохраняя первое вхождение. В df остаётся 381 строка. CSV на диске при этом не переписывается.

`10 df['main_genre'] = df['main_genre'].str.strip().str.lower() # жанры`

Выбирает main_genre. str.strip() удаляет крайние пробелы, str.lower() приводит к нижнему регистру. Исправленные значения записываются обратно в столбец.

`11 df['main_genre'] = df['main_genre'].replace('dramaa', 'drama') # исправляем опечатку`

Заменяет точное ошибочное значение dramaa на drama. Это нормализация категории, а не удаление всех фильмов одного жанра.

```
12 df['main_production'] = df['main_production'].str.strip().str.upper() # страны
```

Удаляет крайние пробелы в кодах стран и переводит их в верхний регистр. Строки us и US стали бы одной категорией.

```
13 df['release_year'] = df['release_year'].astype(int) # год в int
```

Преобразует год в целочисленный тип. Сначала удалены NaN; в этом CSV оставшиеся годы не имеют дробной части. В других данных astype(int) может отбросить дробную часть, поэтому её надо проверять.

```
14 df['number_of_votes'] = df['number_of_votes'].astype(int) # голоса в int
```

Преобразует число голосов в целое. Счётчик голосов по смыслу дискретный; в этих значениях дробной части нет.

```
15 print('\nРазмер после обработки:', df.shape)
```

shape — атрибут с парой (число строк, число столбцов). После обработки печатает (381, 7).

```
16 removed_rows = initial_rows - len(df)
```

Разность начального и текущего размера: удалено всего 8 строк. Переменная не удаляет данные, а хранит результат подсчёта.

```
17 print('\nПропуски после обработки:')
```

Печатает заголовок повторной проверки; на df не влияет.

```
18 print(df.isna().sum())
```

Повторно считает пропуски по столбцам. Все значения должны быть равны нулю.

```
19 print('\nДубликаты после обработки:', df.duplicated().sum())
```

Повторно считает полные дубликаты после нормализации. В этих данных новых дублей не возникло. Для другого CSV нормализация могла бы создать новые полные повторы.

Результат: рисунок 4 в отчёте

```
Пропуски до обработки:
title              5
release_year       2
score              3
number_of_votes    1
duration           0
main_genre         0
main_production    1
dtype: int64

Дубликаты до обработки: 2

Размер после обработки: (381, 7)

Пропуски после обработки:
title              0
release_year       0
score              0
number_of_votes    0
duration           0
main_genre         0
main_production    0
dtype: int64

Дубликаты после обработки: 0
```

Рисунок 4 из выполненной ЛР2.

Как читать и объяснять

• Это проверка обработки, а не график зависимости.

• 389 − 6 − 2 = 381. Двенадцать пустых ячеек не означают 12 удалённых строк.

Краткий ответ на защите: Удалены 6 строк с пропусками и 2 дубля, категории и типы исправлены.

5.5. Блок 5: Повторная проверка после очистки

Данные и выборка: 381 запись, 7 исходных признаков.

Что должно получиться: Во всех числовых столбцах count = 381, пропусков и дублей нет; жанров 15.

```
1 df.info()
2 display(df.describe())
3 print('Уникальных жанров:', df['main_genre'].nunique())
4 print('Строк до обработки:', initial_rows)
5 print('Строк с пропусками:', missing_rows)
6 print('Строк после обработки:', len(df))
7 assert df.isna().sum().sum() == 0
8 assert df.duplicated().sum() == 0
```

Код 5. Полная ячейка с нумерацией строк.

Построчный разбор

```
01 df.info()
```

Показывает типы и заполненность уже очищенной таблицы: 381 строка; release_year и number_of_votes имеют целочисленный тип.

```
02 display(df.describe())
```

Явно отображает describe() после очистки. Эта таблица является основанием для дальнейших численных выводов; её нельзя путать со статистикой исходных 389 строк.

```
03 print('Уникальных жанров:', df['main_genre'].nunique())
```

nunique() считает различные непустые жанры. После нормализации их 15.

```
04 print('Строк до обработки:', initial_rows)
```

Выводит сохранённое исходное число строк: 389.

```
05 print('Строк с пропусками:', missing_rows)
```

Выводит число строк хотя бы с одним пропуском: 6.

```
06 print('Строк после обработки:', len(df))
```

Выводит текущую длину df: 381.

```
07 assert df.isna().sum().sum() == 0
```

Первый sum() даёт пропуски по столбцам, второй — их общее число. assert требует ноль, иначе останавливает выполнение с AssertionError.

```
08 assert df.duplicated().sum() == 0
```

assert проверяет, что полных дубликатов не осталось. Это контроль результата, а не команда удаления.

Результат: рисунок 5 в отчёте

	release_year	score	number_of_votes	duration
count	381.000000	381.000000	3.810000e+02	381.000000
mean	2010.997375	7.509186	1.362626e+05	123.530184
std	10.862659	0.445084	2.350996e+05	28.528329
min	1954.000000	6.900000	1.013900e+04	28.000000
25%	2008.000000	7.100000	2.043000e+04	104.000000
50%	2014.000000	7.400000	4.491700e+04	122.000000
75%	2018.000000	7.800000	1.534630e+05	139.000000
max	2022.000000	9.000000	2.268288e+06	229.000000

Рисунок 5 из выполненной ЛР2.

Как читать и объяснять

• Все count равны 381: сравниваемые характеристики рассчитаны по одной полной таблице.

• Для голосов среднее заметно выше медианы; это согласуется с длинным правым хвостом.

Краткий ответ на защите: Во всех числовых столбцах count = 381, пропусков и дублей нет; жанров 15.

5.6. Блок 6: Матрица диаграмм рассеяния

Данные и выборка: Все 381 записи и 4 числовых признака.

Что должно получиться: Сетка 4×4: 4 гистограммы и 12 направленных диаграмм, представляющих 6 уникальных пар.

```
num_cols = ['release_year', 'score', 'number_of_votes', 'duration']

pd.plotting.scatter_matrix(
    df[num_cols],
    figsize=(9, 9),
    diagonal='hist',
    alpha=0.6
)

plt.show()
```

Код 6. Полная ячейка с нумерацией строк.

Построчный разбор

`01 num_cols = ['release_year', 'score', 'number_of_votes', 'duration']`

Создаёт обычный список имён четырёх числовых столбцов. Текстовые названия и категории не включаются в матрицу.

`03 pd.plotting.scatter_matrix(`

Начинает вызов pandas scatter_matrix: создаётся сетка попарных диаграмм для выбранных признаков.

`04 df[num_cols],`

Двойной выбор через список имён возвращает DataFrame из четырёх числовых столбцов и всех 381 очищенной строки.

`05 figsize=(9, 9),`

Задаёт ширину и высоту общей фигуры в дюймах. Это параметр изображения, а не объём выборки.

`06 diagonal='hist',`

На диагонали матрицы рисуются гистограммы одного признака. Вне диагонали — пары разных признаков.

`07 alpha=0.6`

Непрозрачность точек равна 0,6. Частичное наложение становится заметнее. Ни одна строка из-за alpha не исключается.

```
08 )
```

Закрывает многострочный вызов функции или метода. Отдельного расчёта не выполняет; Python воспринимает аргументы выше как один вызов.

```
10 plt.show()
```

Выводит подготовленную фигуру. В Colab это отображение результата; исходная таблица и статистические характеристики не меняются.

Результат: рисунок 6 в отчёте

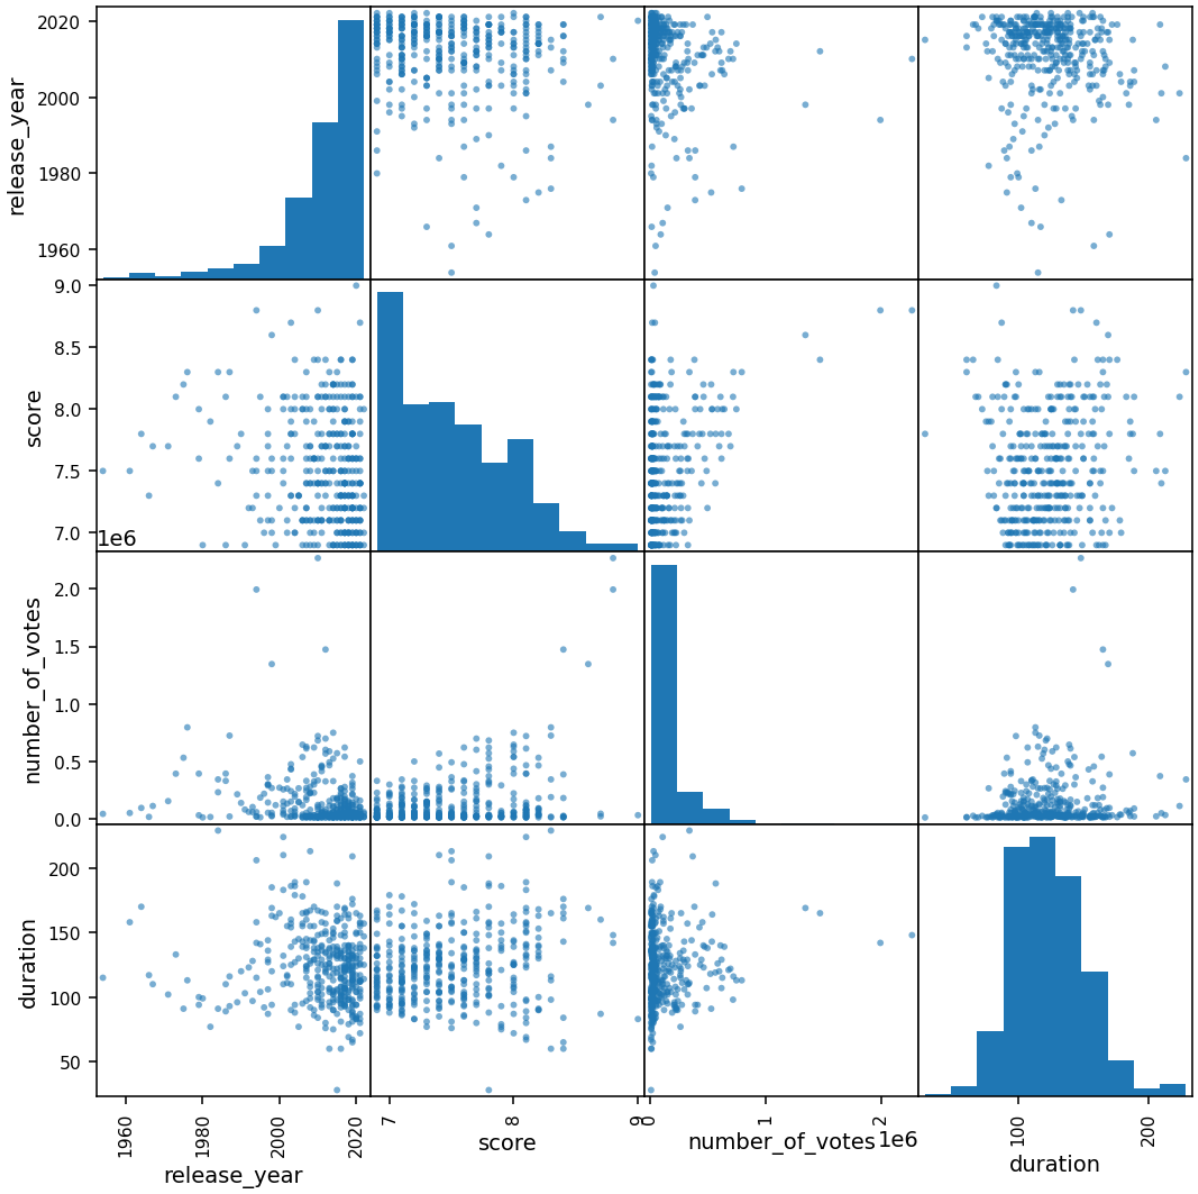


Рисунок 6 из выполненной ЛР2.

Как читать и объяснять

• Выберите столбец матрицы для оси x и строку для оси y. Одна точка — один фильм.

• Восходящее вытянутое облако указывает на прямую связь, нисходящее — на обратную; изгиб может означать нелинейность.

• На диагонали показаны распределения, а не корреляции. Симметричные ячейки повторяют пары с переставленными осями.

Краткий ответ на защите: Сетка 4×4: 4 гистограммы и 12 направленных диаграмм, представляющих 6 уникальных пар.

5.7. Блок 7: Рассеяние по шести жанрам

Данные и выборка: 325 фильмов: drama 148, thriller 59, comedy 57, crime 21, documentary 20, romance 20.

Что должно получиться: Одна точка — фильм; цвет — жанр; y отображён на логарифмической шкале.

```
1  genres = df['main_genre'].value_counts().head(6).index  # популярные жанры
2
3  plt.figure(figsize=(10, 6))
4
5  sns.scatterplot(
6      data=df[df['main_genre'].isin(genres)],
7      x='score',
8      y='number_of_votes',
9      hue='main_genre'
10 )
11
12 plt.yscale('log')  # удобнее видеть голоса
13 plt.title('Рейтинг и количество голосов по жанрам')
14 plt.xlabel('Рейтинг')
15 plt.ylabel('Количество голосов')
16 plt.show()
```

Код 7. Полная ячейка с нумерацией строк.

Построчный разбор

`01 genres = df['main_genre'].value_counts().head(6).index # популярные жанры`

value_counts() считает фильмы по жанрам и сортирует количества по убыванию. head(6) выбирает шесть групп; index возвращает их названия, а не номера фильмов.

`03 plt.figure(figsize=(10, 6))`

Создаёт новую фигуру 10×6 дюймов; следующий график помещается на неё.

`05 sns.scatterplot(`

Начинает построение диаграммы рассеяния средствами Seaborn.

`06 data=df[df['main_genre'].isin(genres)],`

isin(genres) создаёт маску принадлежности к шести выбранным жанрам. Внешние скобки оставляют 325 строк. Сам df не перезаписывается.

`07 x='score',`

Столбец score задаёт горизонтальную координату: рейтинг фильма.

`08 y='number_of_votes',`

number_of_votes задаёт вертикальную координату: число голосов.

`09 hue='main_genre'`

hue окрашивает точки по категории main_genre. Это разделение по цветам, а не дополнительная числовая ось.

```
10 )
```

Закрывает многострочный вызов функции или метода. Отдельного расчёта не выполняет; Python воспринимает аргументы выше как один вызов.

```
12 plt.yscale('log') # удобнее видеть голоса
```

Меняет только отображение вертикальной оси на логарифмическое. Расстояния соответствуют отношениям, например ×10. Значения столбца в df не логарифмируются.

```
13 plt.title('Рейтинг и количество голосов по жанрам')
```

Задаёт заголовок текущей области графика. Это подпись, а не вычисление зависимости или проверка причинности.

```
14 plt.xlabel('Рейтинг')
```

Подписывает горизонтальную ось. Текст должен соответствовать признаку, переданному в x; данные не преобразует.

```
15 plt.ylabel('Количество голосов')
```

Подписывает вертикальную ось. Важно различать рейтинг, число голосов, среднее и число наблюдений: это разные величины.

```
16 plt.show()
```

Выводит подготовленную фигуру. В Colab это отображение результата; исходная таблица и статистические характеристики не меняются.

Результат: рисунок 7 в отчёте

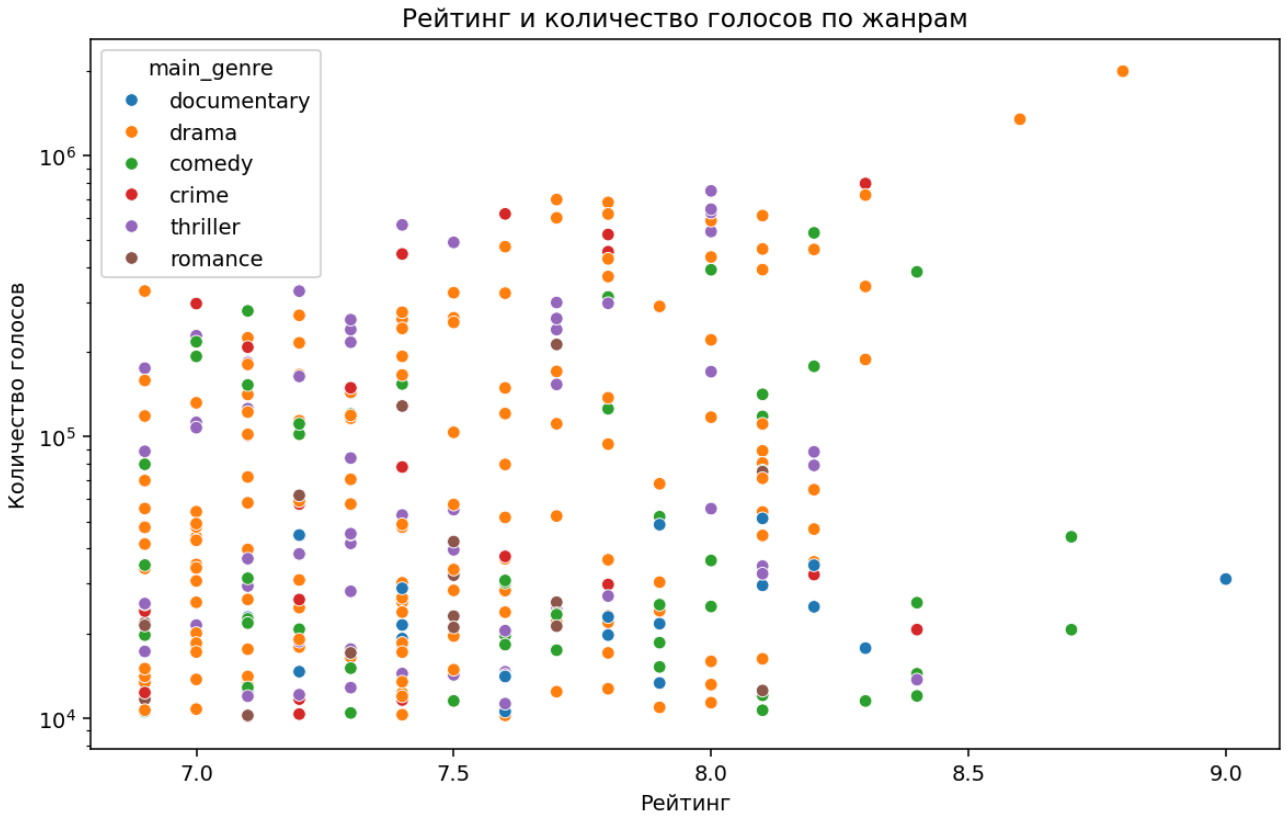


Рисунок 7 из выполненной ЛР2.

Как читать и объяснять

• Ось x — рейтинг, y — голоса; цвет — один из шести жанров.

• На y равные расстояния означают одинаковые отношения. Между 10 тыс. и 100 тыс. столько же расстояния, сколько между 100 тыс. и 1 млн.

• Наложение цветов не образует чётких отдельных групп. Это не доказательство отсутствия любого влияния жанра.

Краткий ответ на защите: Одна точка — фильм; цвет — жанр; y отображён на логарифмической шкале.

5.8. Блок 8: Четыре гистограммы

Данные и выборка: Все 381 записи.

Что должно получиться: На оси y — количество фильмов в интервале, на x — значение текущего признака.

```
1  fig, axes = plt.subplots(2, 2, figsize=(12, 8))
2
3  for ax, column in zip(axes.flat, num_cols):
4      sns.histplot(df[column], bins=15, kde=True, ax=ax)
5      ax.set_title(f'Распределение {column}')
6
7  plt.tight_layout()
8  plt.show()
```

Код 8. Полная ячейка с нумерацией строк.

Построчный разбор

`01 fig, axes = plt.subplots(2, 2, figsize=(12, 8))`

Создаёт одну Figure и массив из 2×2 объектов Axes. fig хранит общую фигуру, axes — четыре области; figsize задаётся в дюймах.

`03 for ax, column in zip(axes.flat, num_cols):`

axes.flat перебирает области в одну линию; zip соединяет их с четырьмя именами num_cols. Цикл последовательно назначает каждой области один признак.

`04 sns.histplot(df[column], bins=15, kde=True, ax=ax)`

histplot строит гистограмму текущего столбца. bins=15 задаёт 15 интервалов, kde=True добавляет сглаженную кривую распределения, ax=ax направляет рисунок в текущую область.

`05 ax.set_title(f'Распределение {column}')`

Метод конкретной области Axes задаёт её заголовок. f-строка подставляет имя текущего столбца вместо {column}.

`07 plt.tight_layout()`

Автоматически регулирует внутренние отступы между четырьмя областями. Исходные значения не меняются.

`08 plt.show()`

Выводит подготовленную фигуру. В Colab это отображение результата; исходная таблица и статистические характеристики не меняются.

Результат: рисунок 8 в отчёте

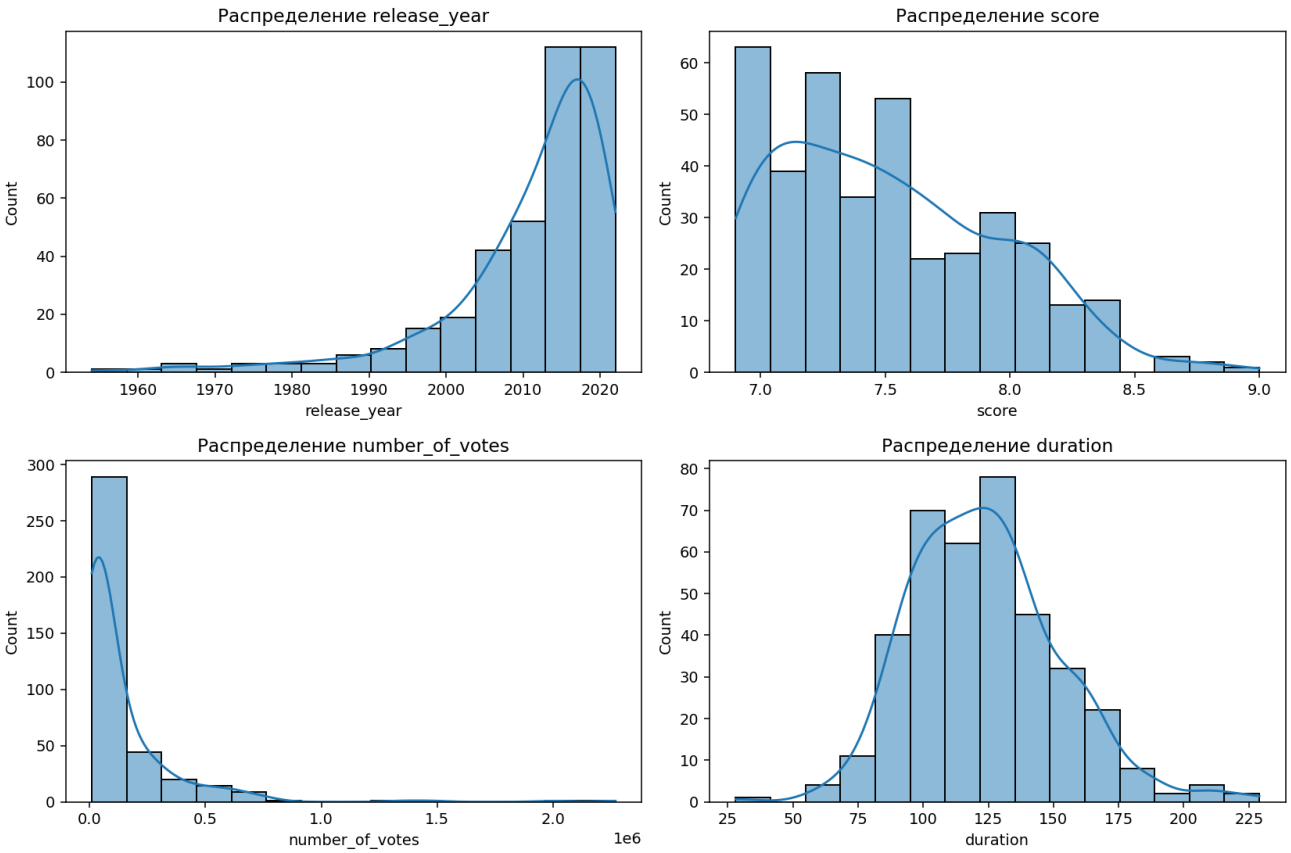


Рисунок 8 из выполненной ЛР2.

Как читать и объяснять

• У каждого из четырёх маленьких графиков свой признак по x и count по y.

• Высота — сколько фильмов оказалось в интервале, а не сколько голосов в сумме они набрали.

• Кривая KDE показывает сглаженную форму; она не предсказывает значение другого признака.

• У количества голосов длинный правый хвост; у длительности среднее близко к медиане. Нормальность отдельно не проверялась.

Краткий ответ на защите: На оси y — количество фильмов в интервале, на x — значение текущего признака.

5.9. Блок 9: Численная проверка распределений

Данные и выборка: Все 381 записи для каждого из четырёх числовых столбцов.

Что должно получиться: Голоса: среднее 136 262,61, медиана 44 917. Рейтинг: медиана 7,4; длительность: 122 минуты.

```
1 display(df[num_cols].agg(['mean', 'median', 'min', 'max']))
```

Код 9. Полная ячейка с нумерацией строк.

Построчный разбор

```
01 display(df[num_cols].agg(['mean', 'median', 'min', 'max']))
```

Выбирает четыре числовых столбца, agg применяет к каждому список функций mean, median, min и max, display показывает таблицу. Здесь нет группировки фильмов по категориям.

5.10. Блок 10: Корреляционная матрица и heatmap

Данные и выборка: Все 381 записи без NaN.

Что должно получиться: Наиболее заметна положительная связь score–votes: 0,347352. Шкала фиксирована на [−1;+1].

```
1  corr = df[num_cols].corr()  # корреляция
2
3  display(corr)
4
5  plt.figure(figsize=(8, 6))
6
7  sns.heatmap(
8      corr,
9      annot=True,
10     cmap='coolwarm',
11     vmin=-1,
12     vmax=1
13 )
14
15 plt.title('Матрица корреляции')
16 plt.show()
```

Код 10. Полная ячейка с нумерацией строк.

Построчный разбор

```
01 corr = df[num_cols].corr() # корреляция
```

corr() без метода по умолчанию вычисляет коэффициенты Пирсона между числовыми столбцами. Получается матрица 4×4; расчёт идёт по исходным, а не логарифмированным голосам.

```
03 display(corr)
```

Выводит численную матрицу корреляций, чтобы коэффициенты можно было проверить точно, а не только по цвету.

```
05 plt.figure(figsize=(8, 6))
```

Создаёт отдельную фигуру 8×6 дюймов.

```
07 sns.heatmap(
```

Начинает построение тепловой карты.

```
08 corr,
```

Первый аргумент — уже вычисленная матрица corr. Heatmap не пересчитывает корреляции.

```
09 annot=True,
```

annot=True добавляет численные значения в ячейки.

```
10 cmap='coolwarm',
```

coolwarm — название цветовой палитры; в этой шкале отрицательные значения синие, положительные красные.

```
11 vmin=-1,
```

Нижняя граница цветовой шкалы фиксируется на −1.

```
12 vmax=1
```

Верхняя граница шкалы фиксируется на +1. Цвета разных коэффициентов поэтому сопоставимы.

```
13 )
```

Закрывает многострочный вызов функции или метода. Отдельного расчёта не выполняет; Python воспринимает аргументы выше как один вызов.

```
15 plt.title('Матрица корреляции')
```

Задаёт заголовок текущей области графика. Это подпись, а не вычисление зависимости или проверка причинности.

```
16 plt.show()
```

Выводит подготовленную фигуру. В Colab это отображение результата; исходная таблица и статистические характеристики не меняются.

Результат: рисунок 9 в отчёте

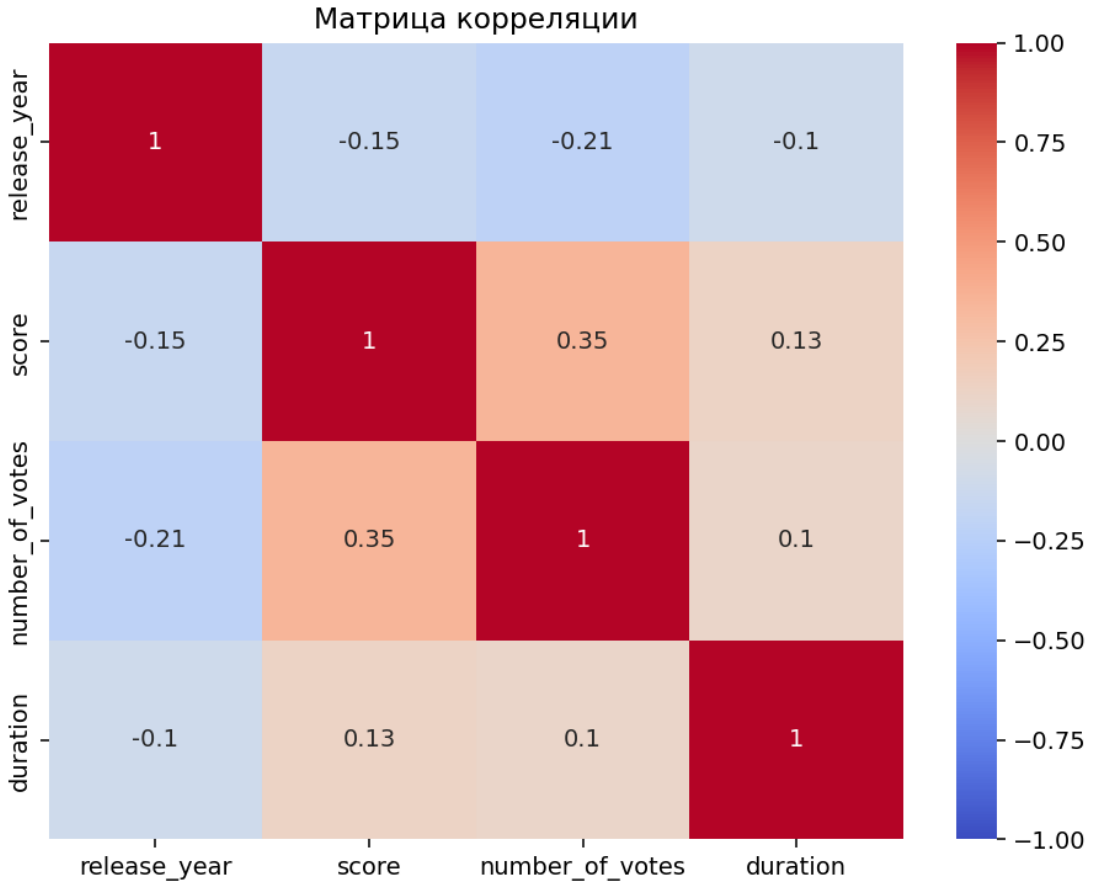


Рисунок 9 из выполненной ЛР2.

Как читать и объяснять

• Сначала прочитайте названия строки и столбца ячейки, затем число, затем цвет.

• Диагональные единицы не являются найденными связями разных признаков.

• Наибольшая по модулю связь разных признаков — score и number_of_votes. Не называйте 0,347 процентом или вероятностью.

Краткий ответ на защите: Наиболее заметна положительная связь score–votes: 0,347352. Шкала фиксирована на [−1;+1].

5.11. Блок 11: Ковариационная матрица

Данные и выборка: Все 381 записи; делитель n−1 = 380.

Что должно получиться: Ковариация score–votes = 36 346,5931; на диагонали находятся дисперсии.

```
1 cov = df[num_cols].cov()  # ковариация
2 display(cov)
```

Код 11. Полная ячейка с нумерацией строк.

Построчный разбор

`01 cov = df[num_cols].cov() # ковариация`

cov() вычисляет выборочную ковариационную матрицу с нормировкой на n−1. На диагонали находятся дисперсии признаков; единицы зависят от исходных шкал.

`02 display(cov)`

Показывает матрицу ковариации. Большое абсолютное число не означает автоматически сильную связь.

Результат: рисунок 10 в отчёте

	release_year	score	number_of_votes	duration
release_year	117.997362	-0.737081	-5.419733e+05	-31.948605
score	-0.737081	0.198100	3.634659e+04	1.613011
number_of_votes	-541973.324720	36346.593100	5.527182e+10	689760.859283
duration	-31.948605	1.613011	6.897609e+05	813.865534

Рисунок 10 из выполненной ЛР2.

Как читать и объяснять

• Знак ковариации интерпретируется аналогично направлению связи, абсолютный масштаб — нет.

• Элементы на диагонали — дисперсии. Квадратный корень из них даёт стандартное отклонение.

Краткий ответ на защите: Ковариация score–votes = 36 346,5931; на диагонали находятся дисперсии.

5.12. Блок 12: Вывод отдельных корреляций

Данные и выборка: Используется уже готовая corr, новые строки не отбираются.

Что должно получиться: Печатаются 0,347; −0,212; 0,127. Округление не изменяет исходную матрицу.

```
print('Рейтинг и количество голосов:', round(corr.loc['score', 'number_of_votes'], 3))
print('Год выхода и количество голосов:', round(corr.loc['release_year',
'number_of_votes'], 3))
print('Длительность и рейтинг:', round(corr.loc['duration', 'score'], 3))
```

Код 12. Полная ячейка с нумерацией строк.

Построчный разбор

`01 print('Рейтинг и количество голосов:', round(corr.loc['score', 'number_of_votes'], 3))`

loc выбирает ячейку на пересечении строки score и столбца number_of_votes. round(..., 3) округляет только вывод до трёх знаков: 0,347.

`02 print('Год выхода и количество голосов:', round(corr.loc['release_year', 'number_of_votes'], 3))`

Извлекает коэффициент года и голосов: около −0,212. Печатается значение корреляции, а не её статистическая значимость.

`03 print('Длительность и рейтинг:', round(corr.loc['duration', 'score'], 3))`

Извлекает коэффициент длительности и рейтинга: около 0,127. loc работает по меткам строк и столбцов.

5.13. Блок 13: Вариант 13: страны и жанры с 2020 года

Данные и выборка: 49 фильмов, условие year ≥ 2020.

Что должно получиться: Цветной столбец — число фильмов заданного жанра и страны.

```
recent = df[df['release_year'] >= 2020]  # фильмы с 2020 года

plt.figure(figsize=(12, 6))

sns.countplot(
    data=recent,
    x='main_production',
    hue='main_genre'
)

plt.title('Количество фильмов по странам и жанрам с 2020 года')
plt.xlabel('Страна производства')
plt.ylabel('Количество фильмов')
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```

Код 13. Полная ячейка с нумерацией строк.

Построчный разбор

```
01 recent = df[df['release_year'] >= 2020] # фильмы с 2020 года
```

Логическое условие включает 2020 год и все более поздние годы. recent содержит 49 строк; исходный очищенный df остаётся полным.

```
03 plt.figure(figsize=(12, 6))
```

Создаёт отдельную фигуру 12×6 дюймов.

```
05 sns.countplot(
```

countplot подсчитывает записи по категориям. В отличие от barplot со средним здесь высота означает количество фильмов.

```
06 data=recent,
```

Источник — recent, а не вся таблица df.

```
07 x='main_production',
```

На горизонтальной оси располагаются страны производства.

```
08 hue='main_genre'
```

Цветные столбцы внутри страны соответствуют жанрам.

```
09 )
```

Закрывает многострочный вызов функции или метода. Отдельного расчёта не выполняет; Python воспринимает аргументы выше как один вызов.

```
11 plt.title('Количество фильмов по странам и жанрам с 2020 года')
```

Задаёт заголовок текущей области графика. Это подпись, а не вычисление зависимости или проверка причинности.

```
12 plt.xlabel('Страна производства')
```

Подписывает горизонтальную ось. Текст должен соответствовать признаку, переданному в x; данные не преобразует.

```
13 plt.ylabel('Количество фильмов')
```

Подписывает вертикальную ось. Важно различать рейтинг, число голосов, среднее и число наблюдений: это разные величины.

```
14 plt.xticks(rotation=45)
```

Поворачивает подписи делений горизонтальной оси на 45 градусов; значения и порядок наблюдений не меняет.

```
15 plt.tight_layout()
```

Уменьшает наложение подписей и границ изображения.

```
16 plt.show()
```

Выводит подготовленную фигуру. В Colab это отображение результата; исходная таблица и статистические характеристики не меняются.

Результат: рисунок 11 в отчёте

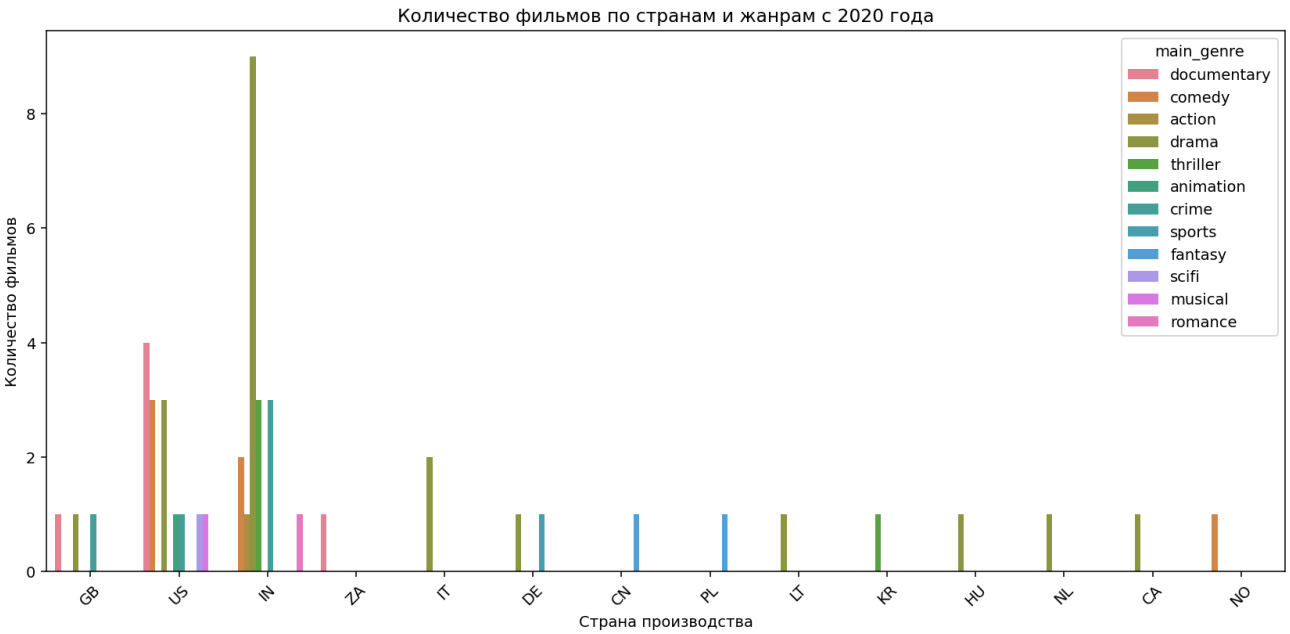


Рисунок 11 из выполненной ЛР2.

Как читать и объяснять

• Ось x содержит страны; рядом стоят столбцы разных цветов-жанров; высота — количество фильмов.

• Группа IN/drama имеет 9 записей. Отсутствующий столбец означает отсутствие комбинации в подвыборке, а не в мировом кино.

• Это countplot, а не средний рейтинг по стране.

Краткий ответ на защите: Цветной столбец — число фильмов заданного жанра и страны.

5.14. Блок 14: Табличное подтверждение countplot

Данные и выборка: Те же 49 фильмов.

Что должно получиться: Крупнейшая группа — IN/drama: 9. head(10) ограничивает число выводимых групп.

```
print('Количество фильмов с 2020 года:', len(recent))
display(recent.groupby(['main_production',
'main_genre']).size().sort_values(ascending=False).head(10).to_frame('Количество
фильмов'))
```

Код 14. Полная ячейка с нумерацией строк.

Построчный разбор

```
01 print('Количество фильмов с 2020 года:', len(recent))
```

len(recent) подтверждает размер подвыборки: 49 фильмов.

```
02 display(recent.groupby(['main_production',
'main_genre']).size().sort_values(ascending=False).head(10).to_frame('Количество фильмов'))
```

groupby создаёт группы страна×жанр; size считает строки; sort_values(ascending=False) ставит самые большие группы первыми; head(10) оставляет десять групп только для отображения; to_frame задаёт название столбца. Это не отбор десяти фильмов.

5.15. Блок 15: Вариант 13: средние голоса после 2010 года

Данные и выборка: 250 фильмов 2011–2022 годов, 12 годовых групп.

Что должно получиться: Один ромб — среднее года. Пик 2012: 327 210,33; минимум 2022: 30 230,20.

```
1  votes_by_year = df[df['release_year'] > 2010].pivot_table(
2      index='release_year',
3      values='number_of_votes',
4      aggfunc='mean'
5  )
6
7  votes_by_year.plot(
8      marker='D',         # ромб
9      linestyle='None',  # без линии
10     color='blue',
11     markersize=14,
12     figsize=(10, 6)
13 )
14
15 plt.title('Среднее количество голосов по годам')
16 plt.xlabel('Год выхода')
17 plt.ylabel('Среднее количество голосов')
18 plt.grid(True)
19 plt.show()
```

Код 15. Полная ячейка с нумерацией строк.

Построчный разбор

```
01 votes_by_year = df[df['release_year'] > 2010].pivot_table(
```

Сначала отбирает 250 фильмов с годом строго больше 2010, то есть с 2011 года. Затем начинает создание сводной таблицы.

```
02 index='release_year',
```

index указывает группирующий признак — год. В результирующей таблице годы становятся метками строк.

```
03 values='number_of_votes',
```

values выбирает агрегируемый столбец — количество голосов.

```
04 aggfunc='mean'
```

aggfunc="mean" рассчитывает арифметическое среднее голосов отдельно внутри каждого года.

```
05 )
```

Закрывает многострочный вызов функции или метода. Отдельного расчёта не выполняет; Python воспринимает аргументы выше как один вызов.

```
07 votes_by_year.plot(
```

Начинает построение графика по уже агрегированным значениям votes_by_year. Одна точка теперь соответствует году, а не отдельному фильму.

```
08 marker='D', # ромб
```

Маркер D — заполненный ромб.

```
09 linestyle='None', # без линии
```

Строка None задаёт отсутствие соединяющей линии. Это строковое имя стиля, а не Python-объект None.

```
10 color='blue',
```

Устанавливает синий цвет маркеров по условию варианта.

```
11 markersize=14,
```

Размер маркера равен 14 пунктам; это размер символа на рисунке, а не количество фильмов.

```
12 figsize=(10, 6)
```

Фигура имеет размеры 10×6 дюймов.

```
13 )
```

Закрывает многострочный вызов функции или метода. Отдельного расчёта не выполняет; Python воспринимает аргументы выше как один вызов.

```
15 plt.title('Среднее количество голосов по годам')
```

Задаёт заголовок текущей области графика. Это подпись, а не вычисление зависимости или проверка причинности.

```
16 plt.xlabel('Год выхода')
```

Подписывает горизонтальную ось. Текст должен соответствовать признаку, переданному в x; данные не преобразует.

```
17 plt.ylabel('Среднее количество голосов')
```

Подписывает вертикальную ось. Важно различать рейтинг, число голосов, среднее и число наблюдений: это разные величины.

```
18 plt.grid(True)
```

Добавляет фоновую координатную сетку для считывания значений.

```
19 plt.show()
```

Выводит подготовленную фигуру. В Colab это отображение результата; исходная таблица и статистические характеристики не меняются.

Результат: рисунок 12 в отчёте

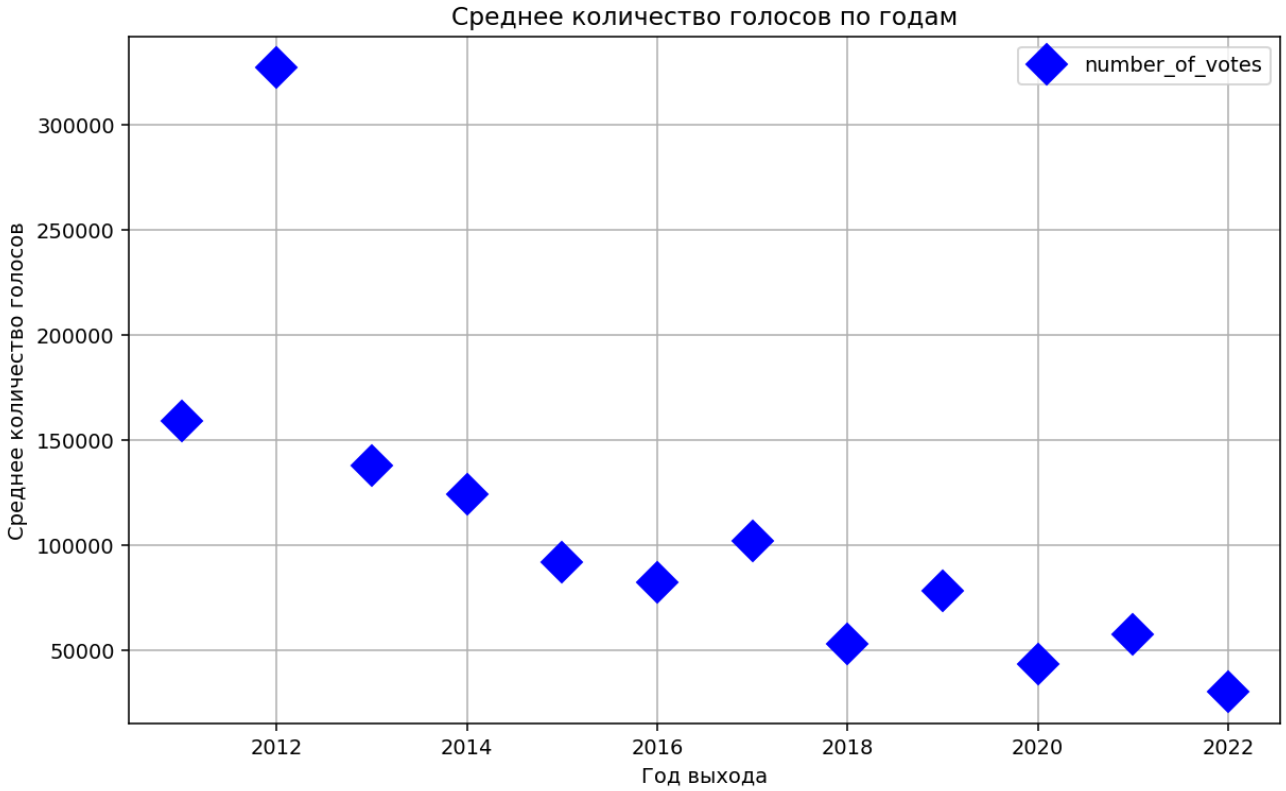


Рисунок 12 из выполненной ЛР2.

Как читать и объяснять

• Каждый ромб представляет годовой агрегат. По x год, по y среднее число голосов.

• В 2012 году 12 фильмов, в 2022 — 5: средние основаны на разных размерах групп.

• После пика нет строго монотонного падения: встречаются подъёмы в 2017, 2019 и 2021 годах.

• Средние чувствительны к единичным популярным фильмам. Время накопления голосов — возможное, но не доказанное объяснение.

Краткий ответ на защите: Один ромб — среднее года. Пик 2012: 327 210,33; минимум 2022: 30 230,20.

5.16. Блок 16: Проверка максимумов и минимумов

Данные и выборка: 12 агрегированных годовых строк.

Что должно получиться: idxmax/idxmin возвращают годы, а не значения среднего.

```
    display(votes_by_year)
1   print('Максимум среднего числа голосов, год:',
2   votes_by_year['number_of_votes'].idxmax())
3   print('Минимум среднего числа голосов, год:',
    votes_by_year['number_of_votes'].idxmin())
```

Код 16. Полная ячейка с нумерацией строк.

Построчный разбор

```
01 display(votes_by_year)
```

Отображает все средние по годам, включая точные значения, которые нельзя надёжно считать с рисунка.

```
02 print('Максимум среднего числа голосов, год:', votes_by_year['number_of_votes'].idxmax())
```

idxmax() возвращает метку строки максимального среднего — 2012 год. Само максимальное значение вернул бы max().

```
03 print('Минимум среднего числа голосов, год:', votes_by_year['number_of_votes'].idxmin())
```

idxmin() возвращает год минимального среднего — 2022. Это не минимальный год в таблице, а год с минимальным средним количеством голосов.

5.17. Блок 17: Вариант 13: доли фильмов по годам

Данные и выборка: Те же 49 фильмов с 2020 года.

Что должно получиться: 2020: 19 и 38,8%; 2021: 25 и 51%; 2022: 5 и 10,2%.

```
1  year_counts = recent['release_year'].value_counts().sort_index()
2
3  plt.figure(figsize=(10, 6))
4
5  plt.pie(
6      year_counts.values,
7      labels=year_counts.index,
8      autopct='%1.1f%%',
9      startangle=90
10 )
11
12 plt.title('Распределение фильмов по годам')
13 plt.legend(year_counts.index, bbox_to_anchor=(1, 1))
14 plt.show()
```

Код 17. Полная ячейка с нумерацией строк.

Построчный разбор

```
01 year_counts = recent['release_year'].value_counts().sort_index()
```

В recent считает фильмы каждого года; sort_index() сортирует годы хронологически, а не по численности. Получаются 19, 25 и 5 записей.

```
03 plt.figure(figsize=(10, 6))
```

Создаёт фигуру 10×6 дюймов.

```
05 plt.pie(
```

Начинает построение круговой диаграммы.

```
06 year_counts.values,
```

values передаёт численные количества. Matplotlib нормирует их на сумму 49 и рассчитывает доли.

```
07 labels=year_counts.index,
```

index задаёт текстовые подписи секторов: 2020, 2021, 2022.

```
08 autopct='%1.1f%%',
```

Строка формата выводит процент с одним знаком после запятой; %% означает буквальный знак процента в результате форматирования.

```
09 startangle=90
```

Начальная граница диаграммы повёрнута на 90°. Это влияет только на расположение секторов.

```
10 )
```

Закрывает многострочный вызов функции или метода. Отдельного расчёта не выполняет; Python воспринимает аргументы выше как один вызов.

```
12 plt.title('Распределение фильмов по годам')
```

Задаёт заголовок текущей области графика. Это подпись, а не вычисление зависимости или проверка причинности.

```
13 plt.legend(year_counts.index, bbox_to_anchor=(1, 1))
```

Добавляет легенду с годами. bbox_to_anchor=(1, 1) задаёт точку привязки в координатах области графика возле её правого верхнего угла.

```
14 plt.show()
```

Выводит подготовленную фигуру. В Colab это отображение результата; исходная таблица и статистические характеристики не меняются.

Результат: рисунок 13 в отчёте

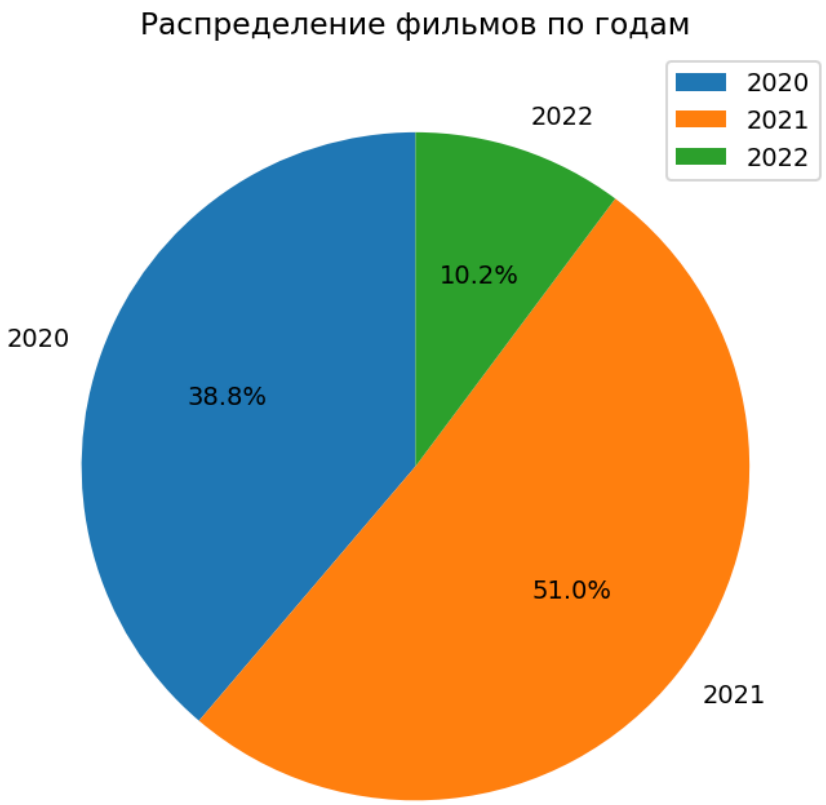


Рисунок 13 из выполненной ЛР2.

Как читать и объяснять

• Сектора показывают долю количества фильмов, а не голосов или рейтинга.

• Самый большой сектор — 2021 год, 25 из 49 = 51%.

• Поворот startangle не меняет доли; подписи могут суммироваться с небольшим округлением.

Краткий ответ на защите: 2020: 19 и 38,8%; 2021: 25 и 51%; 2022: 5 и 10,2%.

5.18. Блок 18: Проверка процентов

Данные и выборка: Три годовых количества; знаменатель 49.

Что должно получиться: Проценты в таблице соответствуют подписям секторов.

```
1  display(pd.DataFrame({'Количество': year_counts, 'Доля, %': (year_counts /
   year_counts.sum() * 100).round(1)}))
```

Код 18. Полная ячейка с нумерацией строк.

Построчный разбор

```
01 display(pd.DataFrame({'Количество': year_counts, 'Доля, %': (year_counts / year_counts.sum() *
100).round(1)}))
```

Создаёт DataFrame из словаря: первый столбец содержит количества, второй — доли. Деление на year_counts.sum() нормирует на 49, умножение на 100 переводит в проценты, round(1) округляет до одного знака.

5.19. Блок 19: Hexbin: длительность и рейтинг

Данные и выборка: 381 фильм.

Что должно получиться: Цвет ячейки — число фильмов; не рейтинг и не средняя длительность.

```
1  df.plot(
2      x='duration',
3      y='score',
4      kind='hexbin',
5      gridsize=20,
6      figsize=(8, 6),
7      grid=True
8  )
9
10 plt.title('Зависимость рейтинга от длительности')
11 plt.xlabel('Длительность')
12 plt.ylabel('Рейтинг')
13 plt.show()
```

Код 19. Полная ячейка с нумерацией строк.

Построчный разбор

```
01 df.plot(
```

Вызывает интерфейс построения графиков Pandas для полной очищенной таблицы.

```
02 x='duration',
```

Горизонтальная координата — длительность.

```
03 y='score',
```

Вертикальная координата — рейтинг.

```
04 kind='hexbin',
```

kind="hexbin" выбирает шестиугольное разбиение плоскости.

```
05 gridsize=20,
```

gridsize=20 задаёт детализацию по горизонтали; это не означает 20 ячеек на всей фигуре.

```
06 figsize=(8, 6),
```

Размер изображения — 8×6 дюймов.

```
07 grid=True
```

Включает фоновые линии сетки. Параметр grid не определяет размеры шестиугольных ячеек.

```
08 )
```

Закрывает многострочный вызов функции или метода. Отдельного расчёта не выполняет; Python воспринимает аргументы выше как один вызов.

```
10 plt.title('Зависимость рейтинга от длительности')
```

Задаёт заголовок текущей области графика. Это подпись, а не вычисление зависимости или проверка причинности.

```
11 plt.xlabel('Длительность')
```

Подписывает горизонтальную ось. Текст должен соответствовать признаку, переданному в x; данные не преобразует.

```
12 plt.ylabel('Рейтинг')
```

Подписывает вертикальную ось. Важно различать рейтинг, число голосов, среднее и число наблюдений: это разные величины.

```
13 plt.show()
```

Выводит подготовленную фигуру. В Colab это отображение результата; исходная таблица и статистические характеристики не меняются.

Результат: рисунок 14 в отчёте

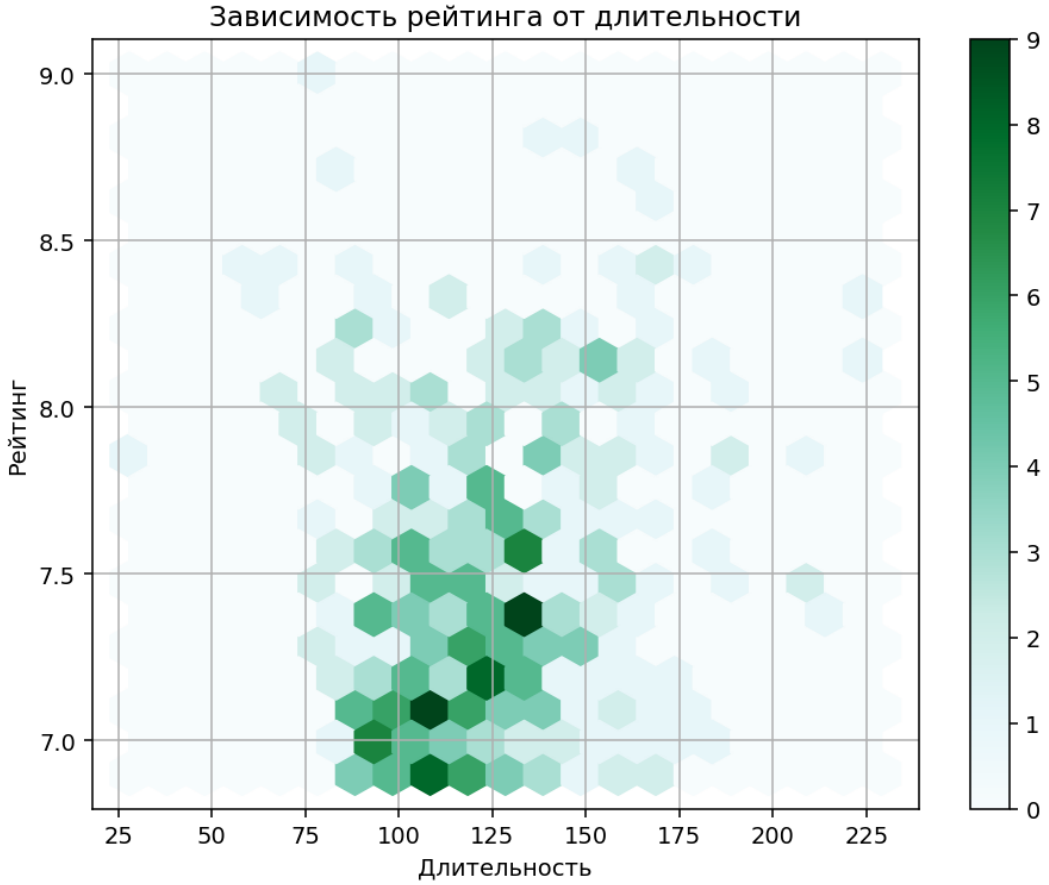


Рисунок 14 из выполненной ЛР2.

Как читать и объяснять

• По x длительность, по y рейтинг. Отдельный шестиугольник объединяет несколько наблюдений.

• Цвет считывайте по шкале справа: здесь он обозначает количество фильмов.

• Сильнее окрашены области большей концентрации, примерно около 100–140 минут и рейтингов 7–8.

• gridsize не равен общему числу ячеек. Не путайте фоновую сетку и разбиение на hexbin.

Краткий ответ на защите: Цвет ячейки — число фильмов; не рейтинг и не средняя длительность.

5.20. Блок 20: Boxplot количества голосов

Данные и выборка: Все 381 записи, включая 39 верхних выбросов.

Что должно получиться: Ящик показывает Q1–Q3, линия — медиану, усы — крайние допустимые наблюдения.

```
1  plt.figure(figsize=(9, 4))
2
3  sns.boxplot(
4      x=df['number_of_votes']
5  )
6
7  plt.title('Диаграмма размаха количества голосов')
8  plt.xlabel('Количество голосов')
9  plt.show()
```

Код 20. Полная ячейка с нумерацией строк.

Построчный разбор

```
01 plt.figure(figsize=(9, 4))
```

Создаёт новую фигуру 9×4 дюйма.

```
03 sns.boxplot(
```

Начинает построение диаграммы размаха Seaborn.

```
04 x=df['number_of_votes']
```

Передаёт Series количества голосов как горизонтальную числовую координату. В выборке все 381 наблюдение, в том числе будущие точки за границами IQR.

```
05 )
```

Закрывает многострочный вызов функции или метода. Отдельного расчёта не выполняет; Python воспринимает аргументы выше как один вызов.

```
07 plt.title('Диаграмма размаха количества голосов')
```

Задаёт заголовок текущей области графика. Это подпись, а не вычисление зависимости или проверка причинности.

```
08 plt.xlabel('Количество голосов')
```

Подписывает горизонтальную ось. Текст должен соответствовать признаку, переданному в x; данные не преобразует.

```
09 plt.show()
```

Выводит подготовленную фигуру. В Colab это отображение результата; исходная таблица и статистические характеристики не меняются.

Результат: рисунок 15 в отчёте

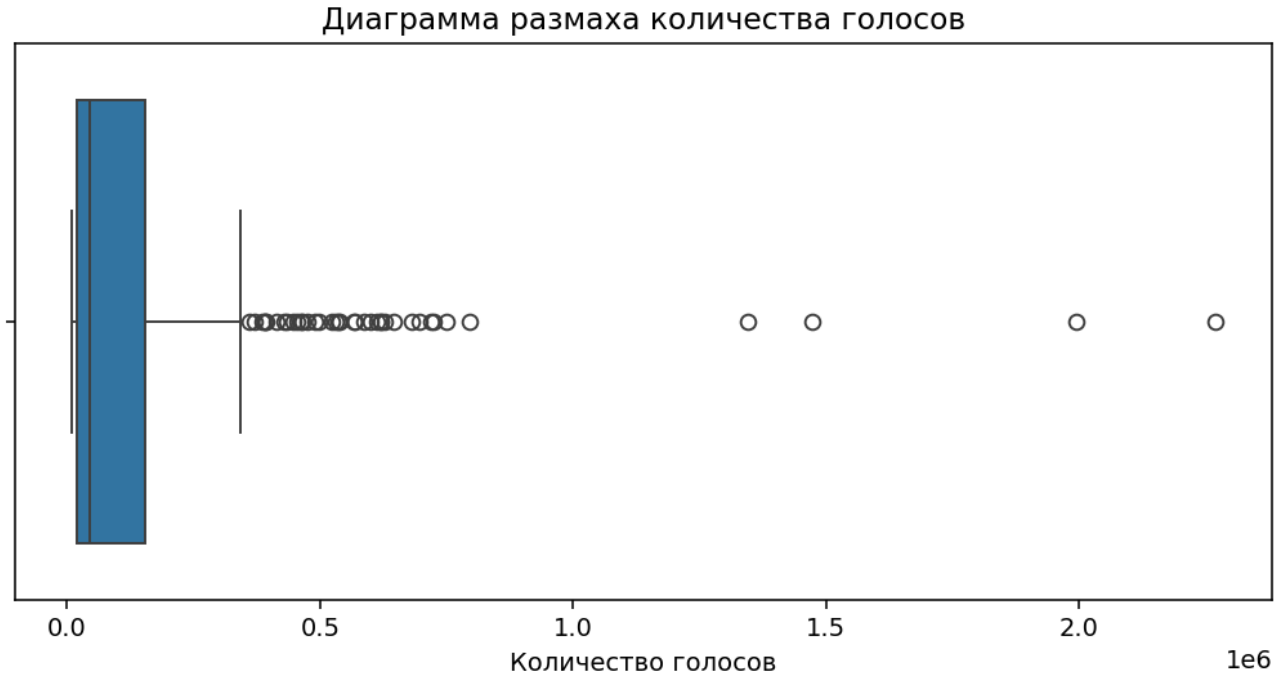


Рисунок 15 из выполненной ЛР2.

Как читать и объяснять

• Найдите Q1, медиану и Q3; оцените, насколько несимметричен ящик.

• Проверьте усы: верхний ус заканчивается на 342 335, а не на расчётной границе 353 012,5.

• Точки справа — 39 необычно популярных записей, которые не были удалены.

• Обычная диаграмма размаха не показывает каждую внутреннюю точку и не кодирует число наблюдений шириной.

Краткий ответ на защите: Ящик показывает Q1–Q3, линия — медиану, усы — крайние допустимые наблюдения.

5.21. Блок 21: Расчёт IQR, границы и уса

Данные и выборка: Исходный очищенный number_of_votes; данные не удаляются.

Что должно получиться: Граница 353 012,5; конец уса 342 335; выше границы 39 фильмов.

```
1 q1, q3 = df['number_of_votes'].quantile([0.25, 0.75])
2 iqr = q3 - q1
3 upper_fence = q3 + 1.5 * iqr
4 upper_whisker = df.loc[df['number_of_votes'] <= upper_fence, 'number_of_votes'].max()
5 print('Верхняя граница по правилу 1,5 IQR:', upper_fence)
6 print('Фактический конец верхнего уса:', upper_whisker)
7 print('Наблюдений выше границы:', (df['number_of_votes'] > upper_fence).sum())
```

Код 21. Полная ячейка с нумерацией строк.

Построчный разбор

```
01 q1, q3 = df['number_of_votes'].quantile([0.25, 0.75])
```

quantile возвращает квартили 0,25 и 0,75. Два значения распаковываются в q1=20 430 и q3=153 463.

```
02 iqr = q3 - q1
```

Рассчитывает межквартильный размах: 153 463 − 20 430 = 133 033.

```
03 upper_fence = q3 + 1.5 * iqr
```

Рассчитывает верхнюю границу 1,5 IQR: 353 012,5. Это теоретическая граница, не обязательно существующее наблюдение.

```
04 upper_whisker = df.loc[df['number_of_votes'] <= upper_fence, 'number_of_votes'].max()
```

loc оставляет голоса не выше границы и max берёт максимальное оставшееся значение: 342 335. Именно там заканчивается верхний ус.

```
05 print('Верхняя граница по правилу 1,5 IQR:', upper_fence)
```

Печатает расчётную границу; не изменяет данные и ничего не удаляет.

```
06 print('Фактический конец верхнего уса:', upper_whisker)
```

Печатает фактический конец верхнего уса, чтобы не путать его с границей.

```
07 print('Наблюдений выше границы:', (df['number_of_votes'] > upper_fence).sum())
```

Сравнение создаёт маску значений выше границы, sum считает True. Получается 39 наблюдений. Они остаются в df.

5.22. Блок 22: Категоризация рейтинга и boxplot

Данные и выборка: 381 запись; после добавления score_level в df 8 столбцов, но num_cols остаётся прежним.

Что должно получиться: Три уровня рейтинга: низкий, средний, высокий. Все наблюдения попадают в интервалы.

```
1  df['score_level'] = pd.cut(
2      df['score'],
3      bins=[0, 7.2, 7.7, 10],
4      labels=['низкий', 'средний', 'высокий']
5  )
6
7  plt.figure(figsize=(8, 5))
8
9  sns.boxplot(
10     data=df,
11     x='score_level',
12     y='score'
13 )
14
15 plt.title('Рейтинг фильмов по категориям')
16 plt.xlabel('Уровень рейтинга')
17 plt.ylabel('Рейтинг')
18 plt.show()
```

Код 22. Полная ячейка с нумерацией строк.

Построчный разбор

```
01 df['score_level'] = pd.cut(
```

Создаёт новый столбец score_level и начинает категоризацию исходного рейтинга.

```
02 df['score'],
```

Первый аргумент — числовая Series рейтинга.

```
03 bins=[0, 7.2, 7.7, 10],
```

Четыре границы образуют три интервала. При настройках по умолчанию: (0;7,2], (7,2;7,7], (7,7;10].

```
04 labels=['низкий', 'средний', 'высокий']
```

Названия категорий назначаются интервалам в том же порядке. Это порядковый категориальный признак.

```
05 )
```

Закрывает многострочный вызов функции или метода. Отдельного расчёта не выполняет; Python воспринимает аргументы выше как один вызов.

```
07 plt.figure(figsize=(8, 5))
```

Создаёт фигуру 8×5 дюймов.

```
09 sns.boxplot(
```

Строит отдельные boxplot внутри каждой новой категории.

```
10 data=df,
```

Источник — все 381 очищенная запись с добавленным score_level.

```
11 x='score_level',
```

На горизонтальной оси — низкий, средний, высокий уровни.

```
12 y='score'
```

На вертикальной оси — исходные значения рейтинга, а не числовые коды категорий.

```
13 )
```

Закрывает многострочный вызов функции или метода. Отдельного расчёта не выполняет; Python воспринимает аргументы выше как один вызов.

```
15 plt.title('Рейтинг фильмов по категориям')
```

Задаёт заголовок текущей области графика. Это подпись, а не вычисление зависимости или проверка причинности.

```
16 plt.xlabel('Уровень рейтинга')
```

Подписывает горизонтальную ось. Текст должен соответствовать признаку, переданному в x; данные не преобразует.

```
17 plt.ylabel('Рейтинг')
```

Подписывает вертикальную ось. Важно различать рейтинг, число голосов, среднее и число наблюдений: это разные величины.

```
18 plt.show()
```

Выводит подготовленную фигуру. В Colab это отображение результата; исходная таблица и статистические характеристики не меняются.

Результат: рисунок 16 в отчёте

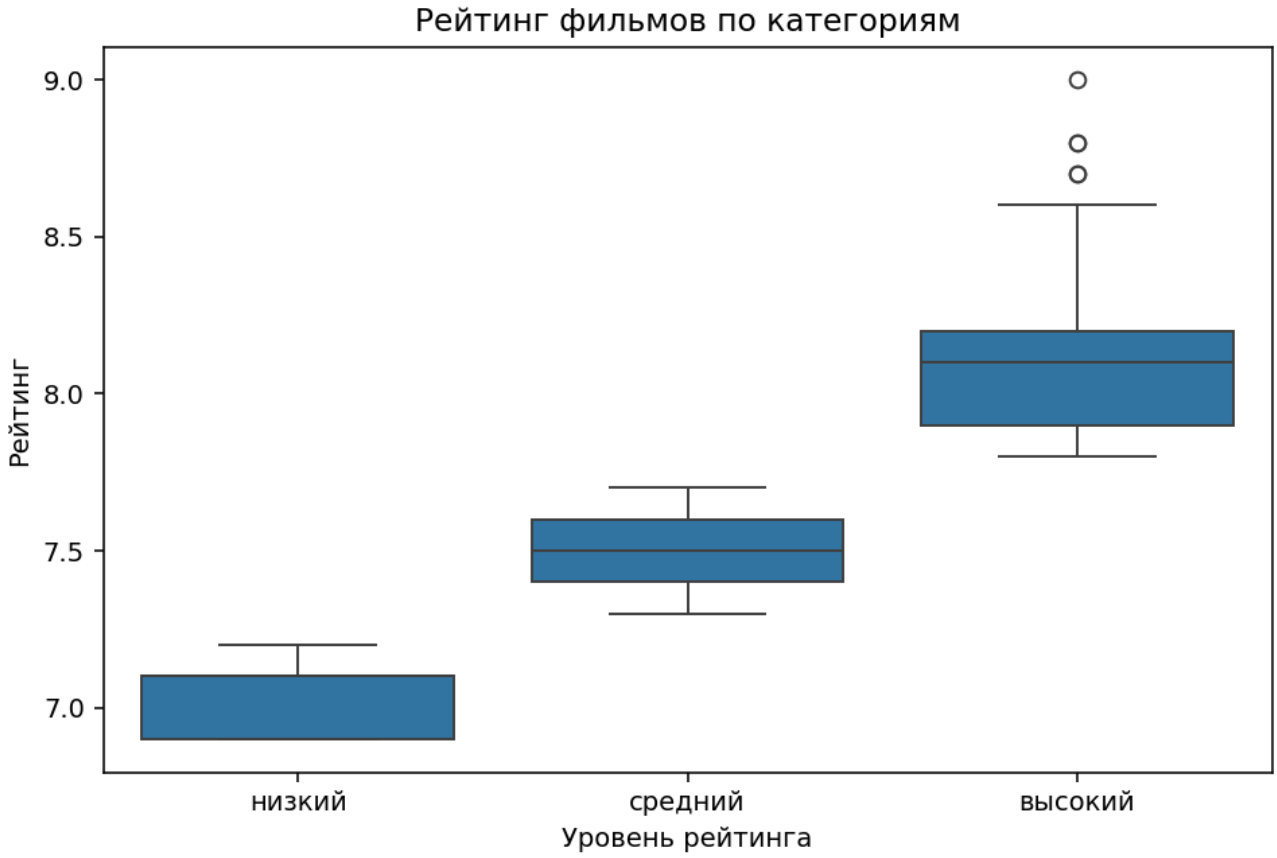


Рисунок 16 из выполненной ЛР2.

Как читать и объяснять

• Ось x — созданные уровни, y — исходный рейтинг; внутри каждого уровня свои квартиль и медиана.

• Рейтинг 7,2 входит в низкий, 7,7 — в средний, 7,8 — в высокий.

• То, что высокая категория имеет более высокий рейтинг, задано cut и не является независимым открытием.

• Численность групп подтверждается таблицей, а не шириной ящиков.

Краткий ответ на защите: Три уровня рейтинга: низкий, средний, высокий. Все наблюдения попадают в интервалы.

5.23. Блок 23: Проверка численности уровней

Данные и выборка: Три группы с размерами 132, 137, 112.

Что должно получиться: Медианы 7,1; 7,5; 8,1. Разделение уровней заранее задано границами.

```
1 display(df.groupby('score_level', observed=False)['score'].agg(['count', 'median',
'min', 'max']))
```

Код 23. Полная ячейка с нумерацией строк.

Построчный разбор

```
01 display(df.groupby('score_level', observed=False)['score'].agg(['count', 'median', 'min',
'max']))
```

Группирует рейтинг по score_level и вычисляет count, median, min, max. observed=False сохраняет все определённые категории, даже если бы одна из них оказалась пустой. В текущем CSV размеры групп 132, 137 и 112.

5.24. Блок 24: Boxplot рейтинга по восьми жанрам

Данные и выборка: 352 фильма; top определяется по численности.

Что должно получиться: Медиана documentary 7,8; horror 7,25. Ящики пересекаются.

```
 1 top_genres = df['main_genre'].value_counts().head(8).index
 2
 3 plt.figure(figsize=(11, 6))
 4
 5 sns.boxplot(
 6     data=df[df['main_genre'].isin(top_genres)],
 7     x='main_genre',
 8     y='score'
 9 )
10
11 plt.title('Рейтинг фильмов по жанрам')
12 plt.xlabel('Жанр')
13 plt.ylabel('Рейтинг')
14 plt.xticks(rotation=35)
15 plt.tight_layout()
16 plt.show()
```

Код 24. Полная ячейка с нумерацией строк.

Построчный разбор

```
01 top_genres = df['main_genre'].value_counts().head(8).index
```

Выбирает восемь жанров по количеству записей. Это не топ по среднему рейтингу.

```
03 plt.figure(figsize=(11, 6))
```

Создаёт фигуру 11×6 дюймов.

```
05 sns.boxplot(
```

Начинает сравнение распределений рейтинга по жанрам.

```
06 data=df[df['main_genre'].isin(top_genres)],
```

Маска оставляет 352 фильма из восьми жанров, основной df не перезаписывается.

```
07 x='main_genre',
```

Горизонтальная ось — названия жанров.

```
08 y='score'
```

Вертикальная ось — рейтинг фильма.

```
09 )
```

Закрывает многострочный вызов функции или метода. Отдельного расчёта не выполняет; Python воспринимает аргументы выше как один вызов.

```
11 plt.title('Рейтинг фильмов по жанрам')
```

Задаёт заголовок текущей области графика. Это подпись, а не вычисление зависимости или проверка причинности.

```
12 plt.xlabel('Жанр')
```

Подписывает горизонтальную ось. Текст должен соответствовать признаку, переданному в x; данные не преобразует.

```
13 plt.ylabel('Рейтинг')
```

Подписывает вертикальную ось. Важно различать рейтинг, число голосов, среднее и число наблюдений: это разные величины.

```
14 plt.xticks(rotation=35)
```

Поворачивает названия жанров на 35 градусов для читаемости.

```
15 plt.tight_layout()
```

Настраивает отступы между подписями и границами фигуры.

```
16 plt.show()
```

Выводит подготовленную фигуру. В Colab это отображение результата; исходная таблица и статистические характеристики не меняются.

Результат: рисунок 17 в отчёте

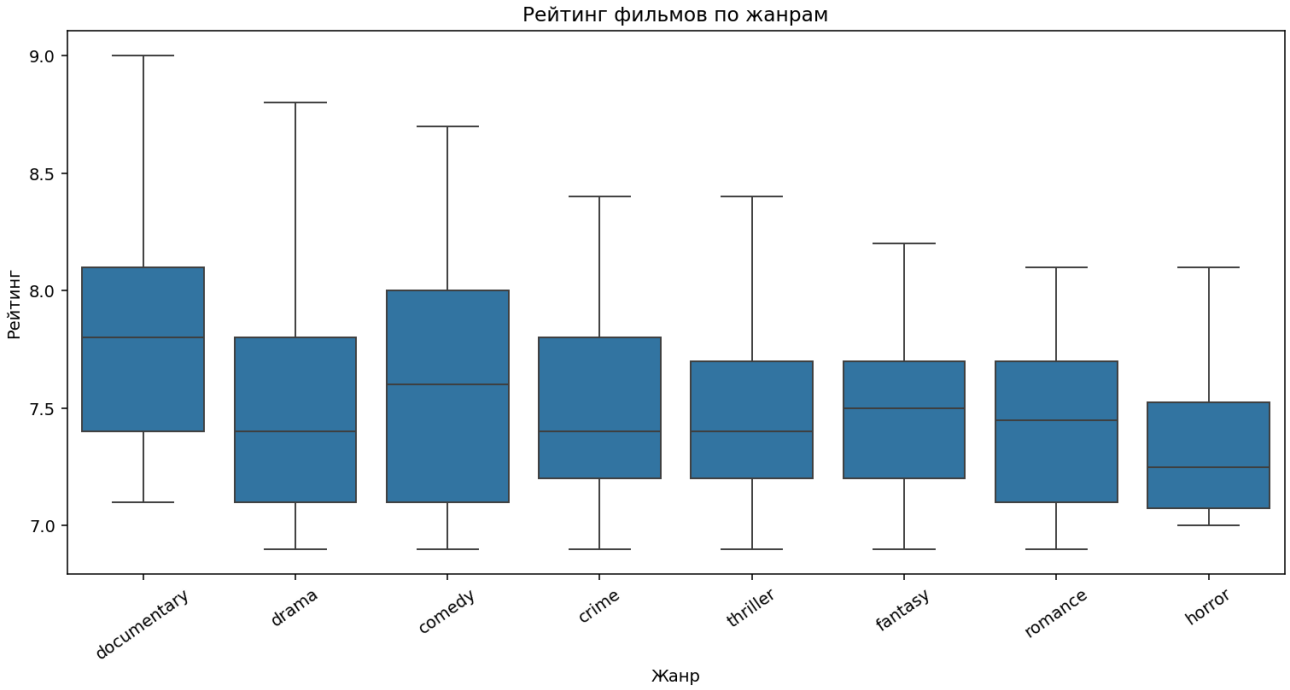


Рисунок 17 из выполненной ЛР2.

Как читать и объяснять

• Сравните медианы, межквартильные размахи, длины усов и отдельные точки.

• У documentary медиана 7,8; у horror точная медиана 7,25. Не заменяйте её необоснованным округлением.

• В drama 148 фильмов, в horror 8, поэтому одинаковая ширина ящиков не означает одинаковый объём данных.

• Перекрытие распределений не позволяет утверждать, что любой фильм одного жанра лучше любого другого.

Краткий ответ на защите: Медиана documentary 7,8; horror 7,25. Ящики пересекаются.

5.25. Блок 25: Boxplot длительности по восьми странам

Данные и выборка: 333 фильма.

Что должно получиться: Медиана IN 148 минут; JP 98 минут. Группы существенно различаются числом фильмов.

```
top_countries = df['main_production'].value_counts().head(8).index

df[df['main_production'].isin(top_countries)].boxplot(
    column='duration',
    by='main_production',
    figsize=(10, 6)
)

plt.suptitle('')
plt.title('Длительность фильмов по странам')
plt.xlabel('Страна производства')
plt.ylabel('Длительность')
plt.show()
```

Код 25. Полная ячейка с нумерацией строк.

Построчный разбор

`01 top_countries = df['main_production'].value_counts().head(8).index`

Находит восемь стран с наибольшим количеством записей и сохраняет только их коды.

`03 df[df['main_production'].isin(top_countries)].boxplot(`

Фильтрует 333 записи выбранных стран и вызывает boxplot через Pandas. Здесь используется другая библиотечная оболочка, чем в предыдущем графике.

`04 column='duration',`

column задаёт анализируемый числовой признак — продолжительность.

`05 by='main_production',`

by задаёт разбиение по странам. Для каждой страны квартили и усы считаются отдельно.

`06 figsize=(10, 6)`

Размер общей фигуры — 10×6 дюймов.

`07 )`

Закрывает многострочный вызов функции или метода. Отдельного расчёта не выполняет; Python воспринимает аргументы выше как один вызов.

`09 plt.suptitle('')`

Удаляет автоматически добавленный Pandas общий заголовок, чтобы он не дублировал пользовательский.

```
10 plt.title('Длительность фильмов по странам')
```

Задаёт заголовок текущей области графика. Это подпись, а не вычисление зависимости или проверка причинности.

```
11 plt.xlabel('Страна производства')
```

Подписывает горизонтальную ось. Текст должен соответствовать признаку, переданному в x; данные не преобразует.

```
12 plt.ylabel('Длительность')
```

Подписывает вертикальную ось. Важно различать рейтинг, число голосов, среднее и число наблюдений: это разные величины.

```
13 plt.show()
```

Выводит подготовленную фигуру. В Colab это отображение результата; исходная таблица и статистические характеристики не меняются.

Результат: рисунок 18 в отчёте

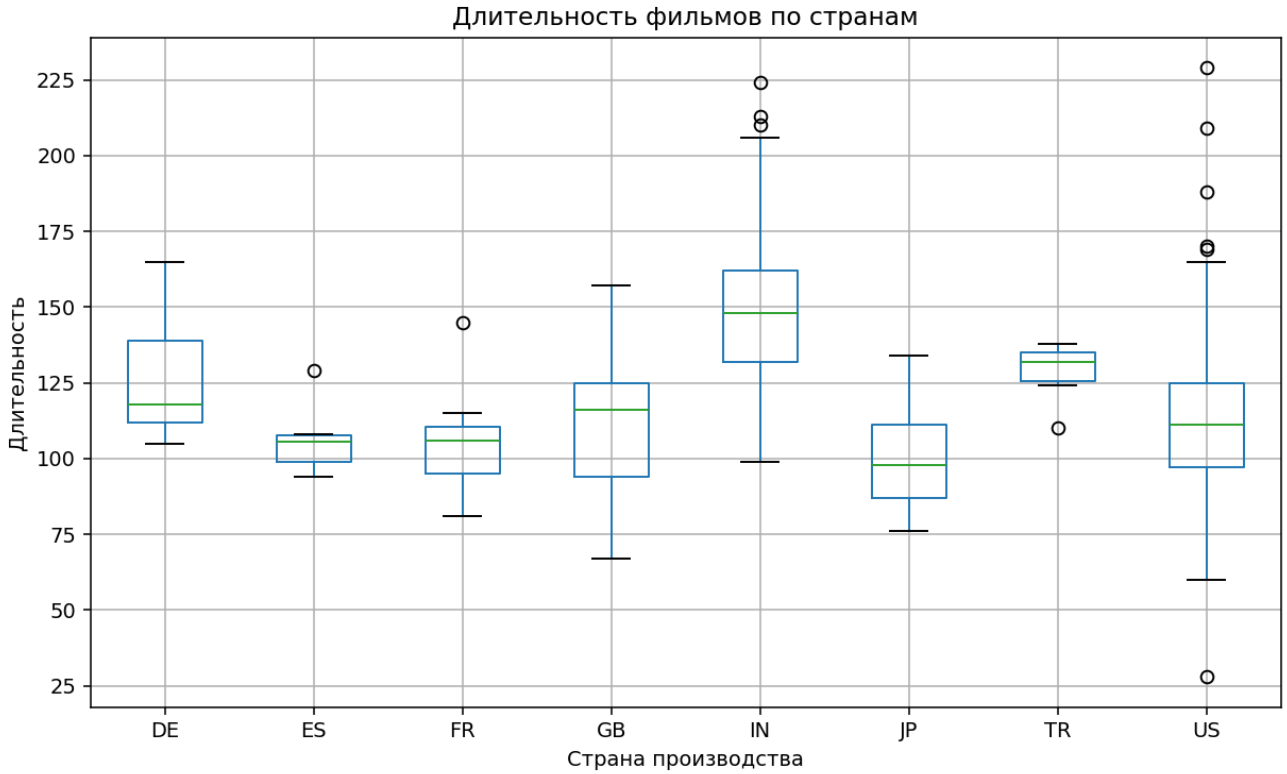


Рисунок 18 из выполненной ЛР2.

Как читать и объяснять

• По x коды стран, по y продолжительность в минутах; статистика считается отдельно для каждой страны.

• Максимальная медиана среди выбранных стран у IN — 148 минут, минимальная у JP — 98.

• Порядок кодов на оси может быть алфавитным; страны отбирались по численности, а не по этому порядку.

• 333 записи не равны всему df: 48 фильмов других стран на этом рисунке отсутствуют.

Краткий ответ на защите: Медиана IN 148 минут; JP 98 минут. Группы существенно различаются числом фильмов.

5.26. Блок 26: Численность и медианы категорий

Данные и выборка: Те же 352 фильма по жанрам и 333 по странам.

Что должно получиться: Таблицы не добавляют новые фильтры: они проверяют те же группы, что показаны на графиках.

```
display(df[df['main_genre'].isin(top_genres)].groupby('main_genre')
['score'].agg(['count', 'median']))
display(df[df['main_production'].isin(top_countries)].groupby('main_production')
['duration'].agg(['count', 'median']))
```

Код 26. Полная ячейка с нумерацией строк.

Построчный разбор

`01 display(df[df['main_genre'].isin(top_genres)].groupby('main_genre')['score'].agg(['count', 'median']))`

Для тех же восьми жанров выводит число фильмов и точную медиану рейтинга. count считает непустые значения score; после очистки оно равно числу строк группы.

`02 display(df[df['main_production'].isin(top_countries)].groupby('main_production')['duration'].agg(['count', 'median']))`

Для тех же восьми стран выводит число фильмов и медиану длительности. Эта таблица нужна, потому что обычная ширина ящиков не кодирует размер группы.

6. Численные результаты, которые полезно знать

Эти таблицы нужны для проверки графиков и устного ответа. Их не обязательно заучивать полностью: важно понимать, откуда берётся каждая величина и какой фильтр использован.

Показатель	Год	Рейтинг	Голоса	Минуты
count	381	381	381	381
mean	2010,997	7,509	136 262,61	123,53
std	10,863	0,445	235 099,59	28,53
min	1954	6,9	10 139	28
Q1	2008	7,1	20 430	104
median	2014	7,4	44 917	122
Q3	2018	7,8	153 463	139
max	2022	9,0	2 268 288	229

6.1. Среднее число голосов по годам

Год	Фильмов	Сумма голосов	Среднее
2011	14	2 228 286	159 163,29
2012	12	3 926 524	327 210,33
2013	15	2 065 981	137 732,07
2014	19	2 361 523	124 290,68
2015	18	1 655 172	91 954,00
2016	26	2 147 836	82 609,08
2017	34	3 463 212	101 859,18
2018	26	1 380 493	53 095,88
2019	37	2 900 066	78 380,16
2020	19	821 864	43 256,00
2021	25	1 440 079	57 603,16
2022	5	151 151	30 230,20

Среднее по всем выбранным фильмам нельзя получить простым средним этих 12 годовых средних, если размеры групп различны. Нужно взвешивать годовое среднее на число фильмов года или считать среднее непосредственно по строкам.

6.2. Численность и медианы жанров

Жанр	Фильмов	Медианный рейтинг
drama	148	7,4
thriller	59	7,4
comedy	57	7,6
crime	21	7,4
documentary	20	7,8
romance	20	7,45
fantasy	19	7,5
horror	8	7,25

На графике рассеяния по категориям берутся только первые шесть жанров из этого списка: 325 наблюдений. Для дополнительного boxplot берутся восемь: 352. В обоих случаях «топ» означает частоту, а не оценку качества.

6.3. Численность и медианы стран

Код	Страна	Фильмов	Медиана длительности
US	США	151	111,0
IN	Индия	115	148,0
GB	Великобритания	29	116,0
JP	Япония	9	98,0
DE	Германия	9	118,0
FR	Франция	7	106,0
TR	Турция	7	132,0
ES	Испания	6	105,5

6.4. Уровни рейтинга

Уровень	Интервал	Фильмов	Медиана
Низкий	(0; 7,2]	132	7,1
Средний	(7,2; 7,7]	137	7,5
Высокий	(7,7; 10]	112	8,1

Фактические минимумы и максимумы этих групп в данных: 6,9–7,2; 7,3–7,7; 7,8–9,0. Границы категорий и фактические пределы наблюдений — разные понятия.

7. Типичные ошибки объяснения и корректные ответы

Неудачная формулировка	Как объяснить правильно
head выбирает случайные записи	head показывает первые строки в текущем порядке.
В таблице 12 строк с пропусками	12 пустых ячеек распределены по 6 строкам.
count — количество пропусков	count в describe — число непустых значений.
Корреляция 0,347 — это вероятность 34,7%	Это безразмерная характеристика линейной связи.
Отрицательная корреляция означает отсутствие связи	Она означает обратное направление линейной связи.
Нулевой r доказывает независимость	Он не исключает нелинейную зависимость.
KDE — линия регрессии	KDE описывает распределение одного признака.
Ромб на рисунке 12 — отдельный фильм	Он показывает среднее число голосов для целого года.
Круг показывает долю голосов	Он показывает долю количества фильмов.
gridsize=20 — всего 20 шестиугольников	Это детализация сетки, а не общее число ячеек.
Ус заканчивается на 353 012,5	Это граница; фактический ус заканчивается на 342 335.
Выбросы надо обязательно удалить	Необычное наблюдение может быть корректным.
Широкий ящик означает больше фильмов	В этих boxplot ширина не кодирует численность.
Топ-8 — жанры с лучшим рейтингом	Они выбраны по количеству записей.
Высокий уровень имеет высокий рейтинг — найденная связь	Это заложено в определении pd.cut.
У новых фильмов меньше голосов, значит год является причиной	Это описательная связь; причинность не исследовалась.

8. Вопросы преподавателя и образцы ответов

Почему файл читается один раз?

Потому что повторный read_csv в ту же переменную восстановил бы исходные пропуски и дубликаты. Все последующие действия должны использовать очищенный df.

Почему было удалено только 6 строк, если пропусков 12?

Потому что несколько пустых ячеек могут принадлежать одной строке. any(axis=1) считает строки с хотя бы одним пропуском.

Почему не заполнили средним?

Для названия и страны среднее бессмысленно. Доля строк мала, поэтому выбран единый способ удаления. Для числовых признаков медианное заполнение возможно, но добавило бы предположения.

Удаление малого числа строк гарантирует отсутствие смещения?

Нет. Даже малая доля может быть систематической. В работе выбран понятный способ обработки, но механизм возникновения пропусков не доказан.

Зачем copy?

Чтобы получить отдельную таблицу после отбора и далее изменять её явно. Это не сохранение файла на диск и не дублирование наблюдений в анализе.

Почему год сначала float?

В исходном столбце есть пропуски. Обычное числовое представление с NaN может иметь float64. После очистки значения целые и преобразованы в int.

Что произойдёт с 2020,7 при astype(int)?

Дробная часть будет отброшена. Поэтому преобразование допустимо только после проверки смысла и дробных частей. В нашем CSV таких дробных годов нет.

Что такое неявные дубликаты?

В рамках проверки категорий — разные написания одной категории. Мы объединили регистры и исправили dramaa. Это отличается от полных повторов строк.

Почему на диаграммах не всегда 381 точка?

Некоторые графики используют фильтры по году или наиболее частые категории. Каждый такой поднабор указан отдельно; это не случайный отбор.

Почему в scatter_matrix 16 ячеек, а пар 6?

Четыре диагональные гистограммы и двенадцать диаграмм для обоих направлений шести пар.

Что показывает alpha?

Непрозрачность. При alpha=0,6 используются все наблюдения, а не 60% строк.

Чем логарифмическая шкала отличается от логарифмирования столбца?

yscale меняет только отображение; столбец сохраняется. Если бы мы записали np.log10 в новый столбец и считали корреляции по нему, это был бы другой расчёт.

Почему bins=15?

Это визуальный компромисс между подробностью и шумом. Универсальная оптимальность не доказывалась; для проверки можно сравнить 8, 15 и 30 интервалов.

Что на диагонали heatmap?

Единицы: корреляция непостоянного признака с самим собой. Они не включаются в поиск наиболее сильной связи разных признаков.

Почему ковариация большая, а корреляция небольшая?

Ковариация зависит от масштаба голосов. После деления на стандартные отклонения получается нормированная корреляция около 0,347.

В каком году фильмов больше, а в каком средние голоса выше?

В поднаборе 2020+ больше фильмов в 2021 — 25. Но максимум среднего голосов для годов после 2010 — 2012. Это разные выборки и показатели.

Что делает pivot_table?

Группирует строки по ключу index и применяет aggfunc к столбцу values. Здесь год — ключ, число голосов — значения, mean — функция.

Почему усы не равны min и max?

Они ограничены наблюдениями внутри 1,5 IQR. Более далёкие значения рисуются отдельно.

Почему выбросов 39, но они остались?

Это потенциально правильные популярные фильмы. Правило IQR отмечает необычность, но не доказывает ошибку.

Почему низкие рейтинги заканчиваются на 7,2?

Так выбраны границы pd.cut. right=True по умолчанию включает правую границу в текущий интервал.

Можно ли по перекрытию boxplot доказать равенство групп?

Нет. Это визуальное описание. Проверка статистических гипотез о распределениях или медианах не выполнялась.

Почему использованы Seaborn и Pandas?

Это требование использовать разные библиотеки для дополнительных boxplot. Математический смысл диаграмм при этом остаётся тем же.

Какая страна или жанр лучше?

По этому набору можно сравнить медианы или средние выбранных групп. Универсальное качество кинематографа или жанра отсюда не следует.

Что изменится, если заменить mean на median?

Годовой агрегат станет менее чувствителен к единичным большим значениям. Числа и расположение точек изменятся, но фильтр годов может остаться тем же.

Можно ли складывать проценты, если они округлены?

Из-за округления итог может отличаться от 100 на десятые. В нашем случае 38,8+51,0+10,2=100,0.

Как проверить, что в notebook нет старых результатов?

Перезапустить среду, выполнить ячейки сверху вниз, проверить итоговые размеры и assert. Сохранённые старые картинки сами по себе не гарантируют новый запуск.

Какова цель вашего вывода?

Связать подготовку данных, численные показатели и графики, указав ограничения. Не просто перечислить команды, а объяснить, что стало известно о наборе.

9. Изменения кода, которые могут попросить на защите

Ниже примеры изменений, а не дополнительные результаты выполненной работы. Если изменить фильтр или функцию, численные выводы нужно пересчитать.

Взять фильмы только 2021 года

```
only_2021 = df[df['release_year'] == 2021]
```

Здесь == означает сравнение. Запись = внутри условия была бы ошибкой.

Взять диапазон 2015–2020 включительно

```
part = df[(df['release_year'] >= 2015) & (df['release_year'] <= 2020)]
```

Каждое условие заключено в скобки; & означает поэлементное логическое И. and для двух Series не подходит.

Вместо среднего взять медиану

```
votes_median = df[df['release_year'] > 2010].pivot_table(index='release_year',
values='number_of_votes', aggfunc='median')
```

Изменяется агрегат, а не количество исходных фильмов в фильтре.

Посчитать сумму голосов по годам

```
votes_sum = df.groupby('release_year')['number_of_votes'].sum()
```

Сумма отвечает на другой вопрос и сильнее зависит от количества фильмов года.

Посчитать фильмы по жанрам

```
genre_counts = df['main_genre'].value_counts()
```

Частоты жанров — не средний рейтинг по жанрам.

Выбрать два конкретных жанра

```
part = df[df['main_genre'].isin(['drama', 'comedy'])]
```

isin проверяет вхождение в список; основные данные не заменяются, если результат записан в part.

Показать относительные частоты

```
shares = df['main_genre'].value_counts(normalize=True) * 100
```

normalize=True возвращает доли; умножение на 100 переводит в проценты.

Изменить количество интервалов

```
sns.histplot(df['duration'], bins=20, kde=True)
```

Меняется детализация гистограммы, но не значения duration и не количество строк.

Изменить порядок boxplot по медиане

```
order = df.groupby('main_genre')['score'].median().sort_values().index
sns.boxplot(data=df, x='main_genre', y='score', order=order)
```

Здесь категории сортируются по медиане; это не тот же порядок, что топ по численности.

10. Готовый связный рассказ о работе

Во второй лабораторной я исследовал movies.csv. Исходно в нём 389 строк и семь столбцов. После удаления шести строк с пропусками и двух полных дубликатов осталось 381 наблюдение. Жанры и страны приведены к единому написанию, год и число голосов — к целым числам. Исходный файл читается один раз, поэтому обработка не сбрасывается.

Матрица рассеяния, гистограммы, корреляции и ковариации показали отсутствие сильных линейных зависимостей. Наиболее заметна положительная связь рейтинга с числом голосов: r около 0,347. Голоса имеют выраженный правый хвост: среднее около 136 тысяч, медиана около 45 тысяч. На логарифмической оси одновременно видны обычные и очень популярные фильмы.

По варианту 13 рассмотрены 49 фильмов с 2020 года. Крупнейшая группа страна–жанр — индийские драмы, 9 фильмов. Для 250 фильмов после 2010 года рассчитаны средние голоса по годам: максимум в 2012, минимум в 2022. Круговая диаграмма показывает, что 25 из 49 фильмов последних лет относятся к 2021 году, то есть 51%.

Hexbin уточнил области концентрации наблюдений. Boxplot выделил 39 необычно больших значений числа голосов, но они не удалялись: высокая популярность может быть корректной. Верхняя граница по правилу IQR равна 353 012,5, фактический ус — 342 335. Дополнительно созданы три уровня рейтинга, сравнены рейтинги по жанрам и длительности по странам. Выводы относятся к данному набору и не устанавливают причинность.

11. Проверочный список перед защитой

- Открыть именно исправленный ноутбук; загрузить исходный CSV и проверить путь.
- Перезапустить среду и выполнить все ячейки последовательно.
- Знать цепочку 389 → 383 → 381 и различие 12 пустых ячеек/6 строк.
- Различать исходную и очищенную статистику.
- Показать, почему графики используют 381, 325, 49, 250, 352 или 333 записи.
- Объяснить одну точку/ромб/ячейку/сектор/ящик на каждом графике.
- Знать формулы среднего, std, ковариации, корреляции, доли и IQR.
- Не путать границу выбросов с концом уса, count с mean, idxmax с max.
- Помнить, что ширина обычного boxplot не показывает число фильмов.

• Не делать выводы о причинности или всём мировом кинематографе.

• Уметь изменить > на >=, mean на median и число bins с последующим пересчётом.

12. Основание разбора и границы интерпретации

Исходные материалы: предоставленный movies.csv; выполненный ноутбук ЛР2_Курбатов_4417_вариант13.ipynb; исправленный отчёт ЛР2 с 18 рисунками; методичка «Лабораторная работа 2. Исследовательский анализ данных», 51 страница. Формулы соответствуют использованным описательным показателям, а не результатам статистических тестов.

Пособие не заменяет исходный ноутбук и не утверждает репрезентативность CSV. Причинные связи, доверительные интервалы, значимость различий, случайность пропусков и нормальность распределений в работе не проверялись. Термины «сильная/слабая связь» используются как описательные, а не как результаты отдельной проверки гипотез.

Проверка полноты: разобраны 26 кодовых блоков и все 194 непустые строки, включены 18 изображений результатов, 26 изображений кода, 14 формул и 4 поясняющие схемы. Числа в таблицах пересчитаны по исходному файлу.